Projet Analyse 3

Serigne Mansour GAYE

2026-01-05

Introduction

La qualité de l'environnement est un enjeu important pour les populations de la région de Thiès, où l'urbanisation et certaines activités humaines peuvent affecter l'air, le bruit et le cadre de vie. Afin de mieux comprendre cette situation, une étude a été menée dans plusieurs localités urbaines, périurbaines et rurales.

L'objectif de cette étude est d'évaluer la qualité de l'air, les nuisances sonores et les conditions météorologiques, tout en analysant les perceptions des populations et l'influence du brûlage de déchets.

Pour cela, des capteurs ont été installés afin de mesurer les PM2.5, le NO_2, le bruit, la température, l'humidité, la pluie, le vent et le NDVI. Ces données ont été complétées par des informations qualitatives et ordinales sur le type de zone, les perceptions de la qualité de l'air et de la gêne du bruit, ainsi que par une variable d'activité liée au brûlage de déchets.

Chargement des librairies

```
library(readxl)

## Warning: le package 'readxl' a été compilé avec la version R 4.3.3
```

Chargement de la base de données

```
df = read_excel(file.choose())
summary(df)

##      Obs_ID         Station            Localite          Type_zone
##  Min.   :  1.00   Length:144         Length:144         Length:144
##  1st Qu.: 36.75   Class :character   Class :character   Class :character
##  Median : 72.50   Mode  :character   Mode  :character   Mode  :character
##  Mean   : 72.50
##  3rd Qu.:108.25
##  Max.   :144.00
##
##   Usage_sol         Risque_inondation       Date
##  Length:144         Length:144         Min.   :2025-01-01 00:00:00
##  Class :character   Class :character   1st Qu.:2025-03-24 06:00:00
```

```
##  Mode  :character   Mode  :character   Median :2025-06-16 00:00:00
##                                        Mean   :2025-05-31 14:00:00
##                                        3rd Qu.:2025-08-08 18:00:00
##                                        Max.   :2025-10-01 00:00:00
##
##  Temperature_C    Humidite_pct      Pluie_mm           Vent_mps
##  Min.   :23.72   Min.   :31.66   Min.   :  0.0409   Min.   :0.200
##  1st Qu.:27.57   1st Qu.:56.67   1st Qu.:  3.3611   1st Qu.:2.263
##  Median :29.08   Median :71.26   Median : 10.1186   Median :2.900
##  Mean   :29.27   Mean   :68.75   Mean   : 18.2943   Mean   :2.967
##  3rd Qu.:30.72   3rd Qu.:79.26   3rd Qu.: 23.9466   3rd Qu.:3.675
##  Max.   :34.90   Max.   :95.00   Max.   :320.0000   Max.   :6.340
##  NA's   :17      NA's   :17      NA's   :17         NA's   :17
##    PM25_ugm3         NO2_ppb          Bruit_dB           NDVI
##  Min.   :  4.00   Min.   :  2.00   Min.   : 40.29   Min.   :-0.2500
##  1st Qu.: 21.24   1st Qu.: 14.45   1st Qu.: 53.93   1st Qu.: 0.2255
##  Median : 34.60   Median : 22.39   Median : 61.88   Median : 0.3050
##  Mean   : 43.37   Mean   : 23.49   Mean   : 60.84   Mean   : 0.3616
##  3rd Qu.: 49.83   3rd Qu.: 30.30   3rd Qu.: 67.25   3rd Qu.: 0.5156
##  Max.   :520.00   Max.   :180.00   Max.   :110.00   Max.   : 1.2500
##  NA's   :17       NA's   :17       NA's   :17       NA's   :17
##  Perception_air_1a5 Gene_bruit_1a5 Qualite_capteur    Brulage_dechets
##  Min.   :2.000      Min.   :1.00   Length:144         Length:144
##  1st Qu.:4.000      1st Qu.:2.00   Class :character   Class :character
##  Median :4.000      Median :2.00   Mode  :character   Mode  :character
##  Mean   :4.094      Mean   :2.22
##  3rd Qu.:4.500      3rd Qu.:3.00
##  Max.   :5.000      Max.   :4.00
##  NA's   :17         NA's   :17
##  Phase_intervention   Campagne         Agent_collecteur   Numero_serie_cap
teur
##  Length:144         Length:144         Length:144         Length:144
##  Class :character   Class :character   Class :character   Class :character
##  Mode  :character   Mode  :character   Mode  :character   Mode  :character
##
##
##
##
##  Commentaire
##  Length:144
##  Class :character
##  Mode  :character
##
##
##
##
```

Commentaire

Statistiques descriptives de la base de données avant traitement.

```r
str(df)
```

```
## tibble [144 × 24] (S3: tbl_df/tbl/data.frame)
##  $ Obs_ID              : num [1:144] 1 2 3 4 5 6 7 8 9 10 ...
##  $ Station             : chr [1:144] "ST01" "ST02" "ST03" "ST04" ...
##  $ Localite            : chr [1:144] "Thiès Nord" "Thiès Est" "Thiès Ouest
" "Médina Fall" ...
##  $ Type_zone           : chr [1:144] "Urbain" "Urbain" "Urbain" "Urbain" .
..
##  $ Usage_sol           : chr [1:144] "Industriel" "Résidentiel" "Résidenti
el" "Mixte" ...
##  $ Risque_inondation   : chr [1:144] "Faible" "Faible" "Moyen" "Faible" ..
.
##  $ Date                : POSIXct[1:144], format: "2025-01-01" "2025-01-01"
...
##  $ Temperature_C       : num [1:144] NA 34.4 30.6 29.5 29.4 ...
##  $ Humidite_pct        : num [1:144] 53.5 NA 55.3 40.6 56 ...
##  $ Pluie_mm            : num [1:144] 8.07 1.87 2.68 8.58 2.98 ...
##  $ Vent_mps            : num [1:144] 3.87 1.89 2.82 2.55 2.66 ...
##  $ PM25_ugm3           : num [1:144] 62.7 43.8 NA 40.6 65.2 ...
##  $ NO2_ppb             : num [1:144] 36.1 25.1 20.6 27.9 27.6 ...
##  $ Bruit_dB            : num [1:144] 78.2 63.6 67.9 68.1 63.2 ...
##  $ NDVI                : num [1:144] 0.12 0.314 0.153 0.224 0.365 ...
##  $ Perception_air_1a5  : num [1:144] 3 4 4 4 3 4 3 4 NA 4 ...
##  $ Gene_bruit_1a5      : num [1:144] 4 2 3 4 NA 3 2 2 NA 1 ...
##  $ Qualite_capteur     : chr [1:144] NA "Bon" "Bon" "Moyen" ...
##  $ Brulage_dechets     : chr [1:144] NA "Non" "Non" NA ...
##  $ Phase_intervention  : chr [1:144] NA NA NA NA ...
##  $ Campagne            : chr [1:144] "Routine" "Routine" "Routine" "Routin
e" ...
##  $ Agent_collecteur    : chr [1:144] "M. Sarr" "M. Sarr" "F. Diop" "S. Ba"
...
##  $ Numero_serie_capteur: chr [1:144] "SENS-38002" "SENS-29387" "SENS-73108
" "SENS-52710" ...
##  $ Commentaire         : chr [1:144] "RAS" "Batterie faible" "RAS" "RAS" .
..
```

Commentaire

La structure de la base de données.

A.Nettoyage et préparation

1.Calculer le taux de NA

Par variable

```r
nbr = colSums(is.na(df))
pourc = colSums(is.na(df))/nrow(df)*100
df_na = data.frame(
  colonne = names(df),
  nb_val_manq = nbr,
```

```r
  pourcentage = round(pourc, 2)
)
row.names(df_na) = NULL
print(df_na)
```

```
##                  colonne nb_val_manq pourcentage
## 1                 Obs_ID           0        0.00
## 2                Station           0        0.00
## 3               Localite           0        0.00
## 4              Type_zone           0        0.00
## 5              Usage_sol           0        0.00
## 6      Risque_inondation           0        0.00
## 7                   Date           0        0.00
## 8          Temperature_C          17       11.81
## 9           Humidite_pct          17       11.81
## 10              Pluie_mm          17       11.81
## 11              Vent_mps          17       11.81
## 12             PM25_ugm3          17       11.81
## 13               NO2_ppb          17       11.81
## 14              Bruit_dB          17       11.81
## 15                  NDVI          17       11.81
## 16    Perception_air_1a5          17       11.81
## 17        Gene_bruit_1a5          17       11.81
## 18       Qualite_capteur          17       11.81
## 19       Brulage_dechets          17       11.81
## 20    Phase_intervention         120       83.33
## 21              Campagne           0        0.00
## 22      Agent_collecteur           0        0.00
## 23 Numero_serie_capteur           0        0.00
## 24           Commentaire          13        9.03
```

Par visualisation(barplot)

```r
barplot(pourc,
        las = 2,
        main = "Taux de valeurs manquantes par variable",
        ylab = "Pourcentage NA")
```

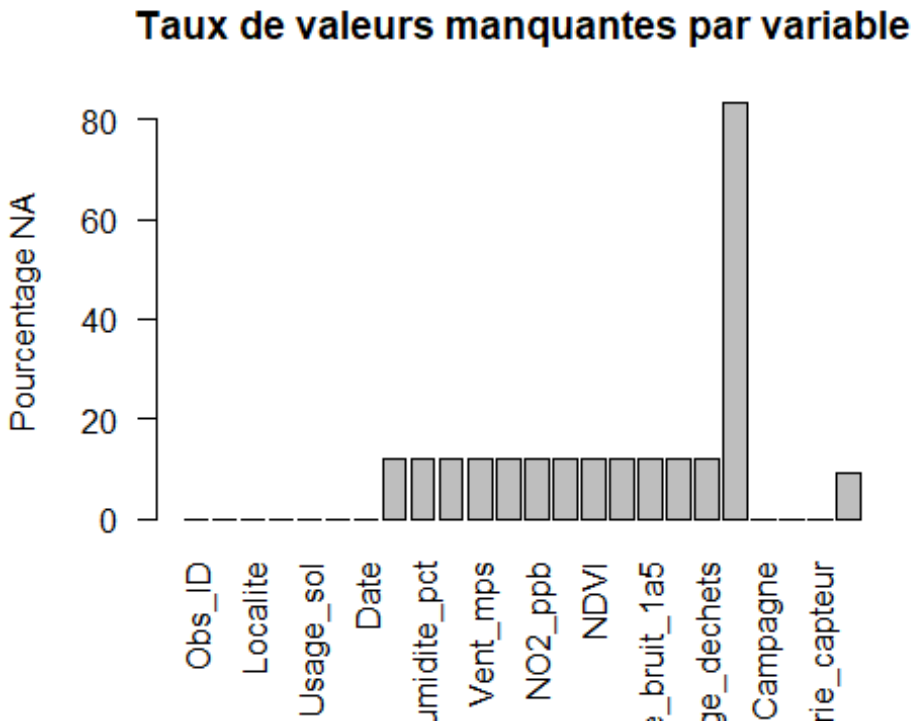

Commentaire

Ce graphique met en évidence que certaines variables quantitatives présentent environ 12 % de valeurs manquantes, tandis que la variable Phase_intervention présente un taux très élevé.

2.Traiter les NA

On constate que la proportion de valeurs manquantes est modérée donc on peut choisir l'imputation simple en imputant les variables quantitatives par la médiane et les variables qualitatives par le mode

Les variables quantitatives

```
df$Temperature_C[is.na(df$Temperature_C)] = median(df$Temperature_C, na.rm =
TRUE)
df$Humidite_pct[is.na(df$Humidite_pct)] = median(df$Humidite_pct, na.rm = TRU
E)
df$Pluie_mm[is.na(df$Pluie_mm)] = median(df$Pluie_mm, na.rm = TRUE)
df$Vent_mps[is.na(df$Vent_mps)] = median(df$Vent_mps, na.rm = TRUE)
df$PM25_ugm3[is.na(df$PM25_ugm3)] = median(df$PM25_ugm3, na.rm = TRUE)
df$NO2_ppb[is.na(df$NO2_ppb)] = median(df$NO2_ppb, na.rm = TRUE)
df$Bruit_dB[is.na(df$Bruit_dB)] = median(df$Bruit_dB, na.rm = TRUE)
df$NDVI[is.na(df$NDVI)] = median(df$NDVI, na.rm = TRUE)
df$Perception_air_1a5[is.na(df$Perception_air_1a5)] = median(df$Perception_ai
r_1a5, na.rm = TRUE)
```

```r
df$Gene_bruit_1a5[is.na(df$Gene_bruit_1a5)] = median(df$Gene_bruit_1a5, na.rm
= TRUE)
```

Les variables qualitatives

```r
table(df$Qualite_capteur)

##
##     Bon Mauvais   Moyen
##      84      16      27

df$Qualite_capteur[is.na(df$Qualite_capteur)] = names(sort(table(df$Qualite_c
apteur), decreasing = TRUE))

table(df$Brulage_dechets)

##
## Non Oui
## 100  27

df$Brulage_dechets[is.na(df$Brulage_dechets)] = names(sort(table(df$Brulage_d
echets), decreasing = TRUE))

table(df$Phase_intervention)

##
## Après Avant
##    12    12

df$Phase_intervention[is.na(df$Phase_intervention)] = names(sort(table(df$Pha
se_intervention), decreasing = TRUE))
table(df$Commentaire)

##
##  Batterie faible  Capteur déplacé Panne temporaire              RAS
##               11                5                5              110

df$Commentaire[is.na(df$Commentaire)] = names(sort(table(df$Commentaire), dec
reasing = TRUE))
```

Après traitement

```r
summary(df)

##      Obs_ID         Station            Localite          Type_zone
##  Min.   :  1.00   Length:144         Length:144         Length:144
##  1st Qu.: 36.75   Class :character   Class :character   Class :character
##  Median : 72.50   Mode  :character   Mode  :character   Mode  :character
##  Mean   : 72.50
##  3rd Qu.:108.25
##  Max.   :144.00
##   Usage_sol         Risque_inondation       Date
##  Length:144         Length:144         Min.   :2025-01-01 00:00:00
##  Class :character   Class :character   1st Qu.:2025-03-24 06:00:00
```

```
##  Mode  :character   Mode  :character   Median :2025-06-16 00:00:00
##                                        Mean   :2025-05-31 14:00:00
##                                        3rd Qu.:2025-08-08 18:00:00
##                                        Max.   :2025-10-01 00:00:00
##  Temperature_C    Humidite_pct      Pluie_mm           Vent_mps
##  Min.   :23.72   Min.   :31.66   Min.   :  0.0409   Min.   :0.200
##  1st Qu.:27.66   1st Qu.:59.20   1st Qu.:  4.1149   1st Qu.:2.342
##  Median :29.08   Median :71.26   Median : 10.1186   Median :2.900
##  Mean   :29.25   Mean   :69.04   Mean   : 17.3291   Mean   :2.959
##  3rd Qu.:30.42   3rd Qu.:78.49   3rd Qu.: 20.9212   3rd Qu.:3.569
##  Max.   :34.90   Max.   :95.00   Max.   :320.0000   Max.   :6.340
##    PM25_ugm3         NO2_ppb          Bruit_dB           NDVI
##  Min.   :  4.00   Min.   :  2.00   Min.   : 40.29   Min.   :-0.2500
##  1st Qu.: 23.78   1st Qu.: 15.60   1st Qu.: 55.61   1st Qu.: 0.2360
##  Median : 34.60   Median : 22.39   Median : 61.88   Median : 0.3050
##  Mean   : 42.34   Mean   : 23.36   Mean   : 60.96   Mean   : 0.3549
##  3rd Qu.: 48.56   3rd Qu.: 29.60   3rd Qu.: 66.03   3rd Qu.: 0.4667
##  Max.   :520.00   Max.   :180.00   Max.   :110.00   Max.   : 1.2500
##  Perception_air_1a5 Gene_bruit_1a5  Qualite_capteur    Brulage_dechets
##  Min.   :2.000      Min.   :1.000   Length:144         Length:144
##  1st Qu.:4.000      1st Qu.:2.000   Class :character   Class :character
##  Median :4.000      Median :2.000   Mode  :character   Mode  :character
##  Mean   :4.083      Mean   :2.194
##  3rd Qu.:4.000      3rd Qu.:3.000
##  Max.   :5.000      Max.   :4.000
##  Phase_intervention   Campagne         Agent_collecteur   Numero_serie_cap
teur
##  Length:144         Length:144         Length:144         Length:144
##  Class :character   Class :character   Class :character   Class :character
##  Mode  :character   Mode  :character   Mode  :character   Mode  :character
##
##
##
##  Commentaire
##  Length:144
##  Class :character
##  Mode  :character
##
##
##
```

Commentaire

Statistiques descriptives de la base de données apres traitement.

3.Detecter les valeurs aberrantes

PM25_ugm3

```r
boxplot(df$PM25_ugm3, main = "Détection des valeurs aberrantes de PM25_ugm3")
```

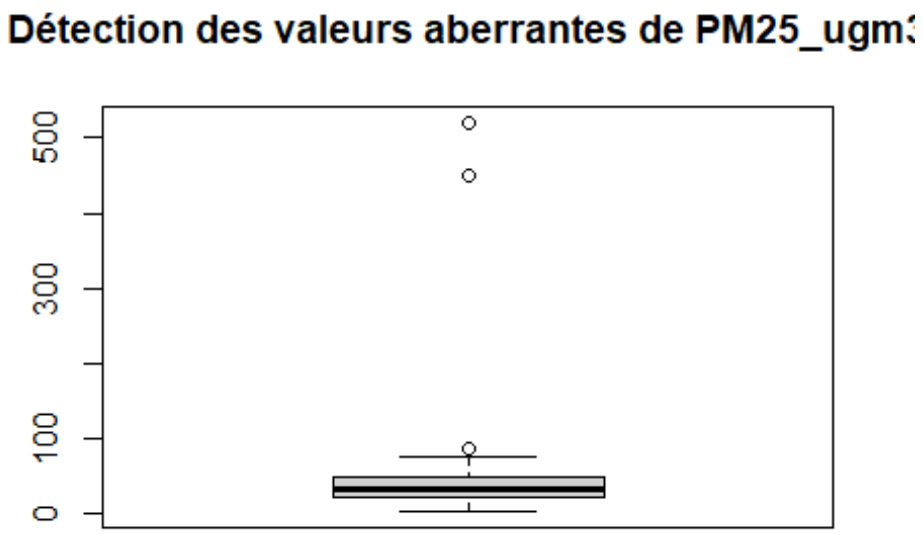

Commentaire

Le boxplot montre la présence de valeurs extrêmes élevées de PM2.5, indiquant des épisodes ponctuels de forte pollution atmosphérique.

NO2_ppb

```
boxplot(df$NO2_ppb, main = "Détection des valeurs aberrantes du NO2_ppb")
```

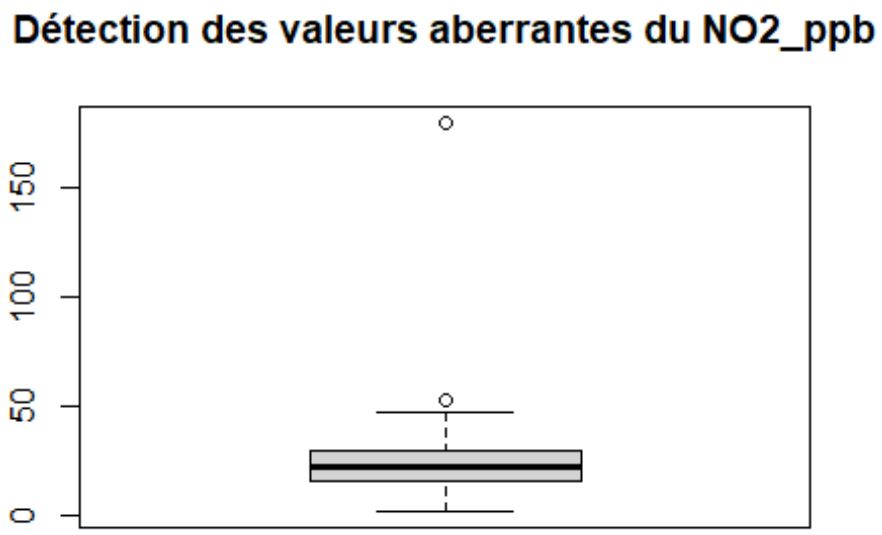

Commentaire

Ce graphique révèle plusieurs valeurs atypiques du NO_2, traduisant une variabilité importante des concentrations selon les périodes.

Bruit_dB

```
boxplot(df$Bruit_dB, main = "Détection des valeurs aberrantes du Bruit_dB")
```

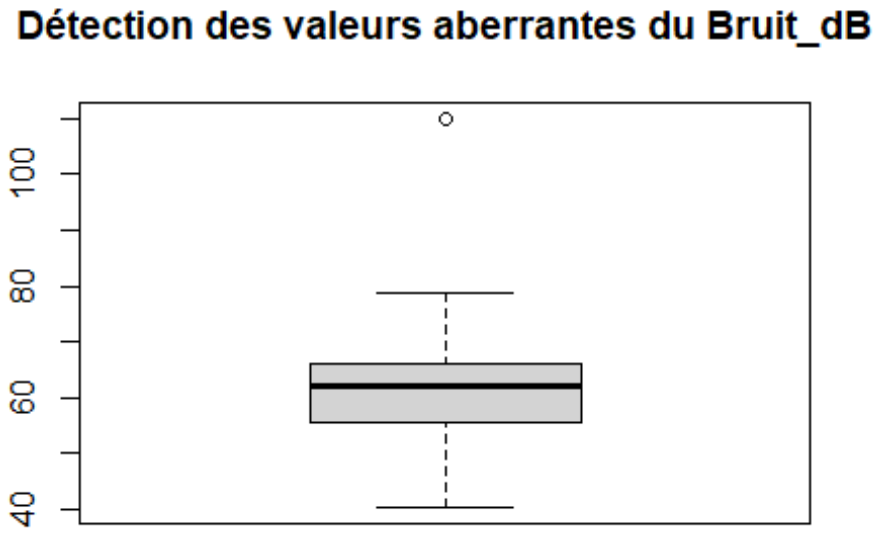

Commentaire

Le boxplot met en évidence des niveaux sonores exceptionnellement élevés, suggérant des zones exposées à des nuisances sonores importantes.

Pluie_mm

```
boxplot(df$Pluie_mm, main = "Détection des valeurs aberrantes de Pluie_mm")
```

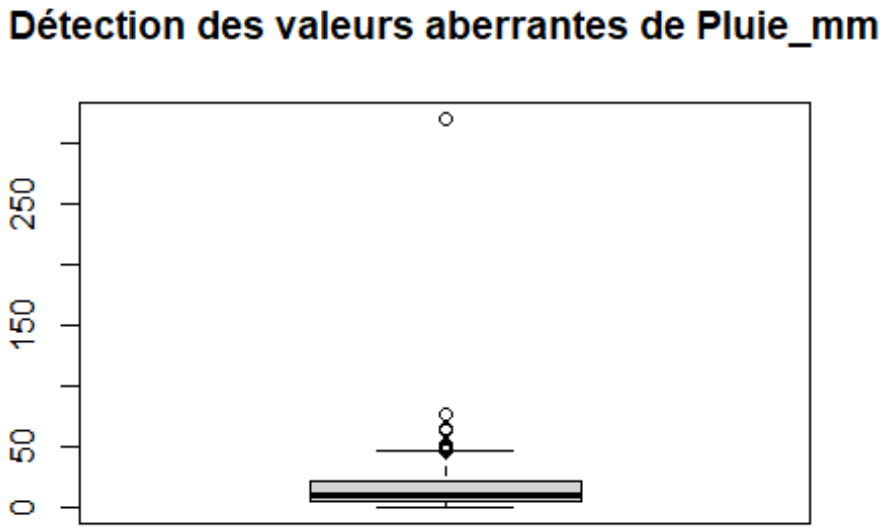

Commentaire

Le boxplot montre une distribution asymétrique avec la présence de valeurs extrêmes correspondant à des épisodes de fortes pluies, susceptibles d'influencer les analyses statistiques.

NDVI

```
boxplot(df$NDVI, main = "Détection des valeurs aberrantes de NDVI")
```

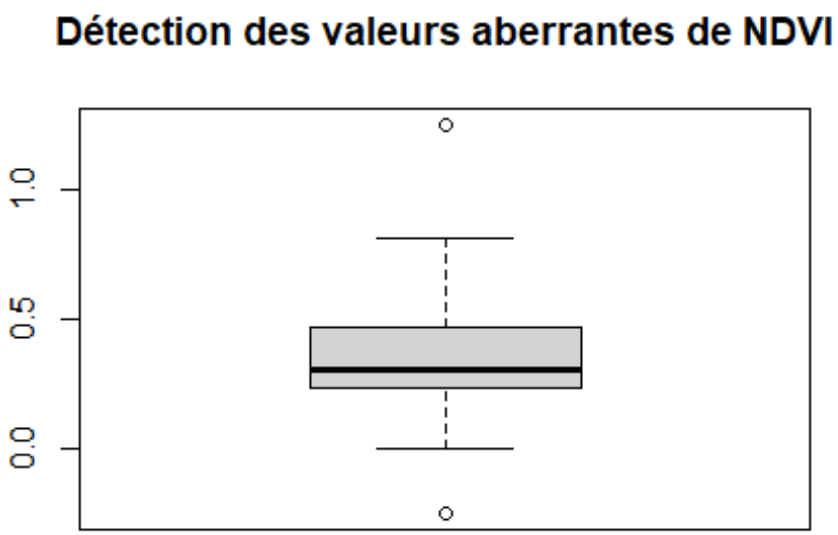

Commentaire

Ce graphique montre des valeurs extrêmes du NDVI, reflétant des zones très faiblement ou fortement végétalisées.

La strategie pour corriger les valeurs aberrantes

La winsorisation a été utilisée afin de réduire l'influence des valeurs extrêmes détectées, tout en conservant l'ensemble des observations.

```
library(DescTools)

## Warning: le package 'DescTools' a été compilé avec la version R 4.3.3

df$PM25_ugm3 = Winsorize(df$PM25_ugm3, val = quantile(df$PM25_ugm3, probs = c
(0.05, 0.95), na.rm = FALSE))
df$NO2_ppb = Winsorize(df$NO2_ppb, val = quantile(df$NO2_ppb, probs = c(0.05,
0.95), na.rm = FALSE))
df$Bruit_dB = Winsorize(df$Bruit_dB, val = quantile(df$Bruit_dB, probs = c(0.
05, 0.95), na.rm = FALSE))
df$Pluie_mm = Winsorize(df$Pluie_mm, val = quantile(df$Pluie_mm, probs = c(0.
05, 0.95), na.rm = FALSE))
df$NDVI = Winsorize(df$NDVI, val = quantile(df$NDVI, probs = c(0.05, 0.95), n
a.rm = FALSE))
```

Apres correction

```
summary(df)
```

```
##      Obs_ID         Station            Localite          Type_zone
##  Min.   :  1.00   Length:144         Length:144         Length:144
##  1st Qu.: 36.75   Class :character   Class :character   Class :character
##  Median : 72.50   Mode  :character   Mode  :character   Mode  :character
##  Mean   : 72.50
##  3rd Qu.:108.25
##  Max.   :144.00
##   Usage_sol         Risque_inondation       Date
##  Length:144         Length:144         Min.   :2025-01-01 00:00:00
##  Class :character   Class :character   1st Qu.:2025-03-24 06:00:00
##  Mode  :character   Mode  :character   Median :2025-06-16 00:00:00
##                                        Mean   :2025-05-31 14:00:00
##                                        3rd Qu.:2025-08-08 18:00:00
##                                        Max.   :2025-10-01 00:00:00
##  Temperature_C    Humidite_pct      Pluie_mm         Vent_mps
##  Min.   :23.72   Min.   :31.66   Min.   : 1.123   Min.   :0.200
##  1st Qu.:27.66   1st Qu.:59.20   1st Qu.: 4.115   1st Qu.:2.342
##  Median :29.08   Median :71.26   Median :10.119   Median :2.900
##  Mean   :29.25   Mean   :69.04   Mean   :14.914   Mean   :2.959
##  3rd Qu.:30.42   3rd Qu.:78.49   3rd Qu.:20.921   3rd Qu.:3.569
##  Max.   :34.90   Max.   :95.00   Max.   :48.373   Max.   :6.340
##    PM25_ugm3         NO2_ppb          Bruit_dB          NDVI
##  Min.   : 5.466   Min.   : 3.835   Min.   :44.71   Min.   :0.07934
##  1st Qu.:23.777   1st Qu.:15.595   1st Qu.:55.61   1st Qu.:0.23602
##  Median :34.597   Median :22.393   Median :61.88   Median :0.30505
##  Mean   :36.506   Mean   :22.272   Mean   :60.69   Mean   :0.35257
##  3rd Qu.:48.560   3rd Qu.:29.604   3rd Qu.:66.03   3rd Qu.:0.46669
##  Max.   :74.063   Max.   :41.037   Max.   :73.31   Max.   :0.69263
##  Perception_air_1a5 Gene_bruit_1a5  Qualite_capteur    Brulage_dechets
##  Min.   :2.000      Min.   :1.000   Length:144         Length:144
##  1st Qu.:4.000      1st Qu.:2.000   Class :character   Class :character
##  Median :4.000      Median :2.000   Mode  :character   Mode  :character
##  Mean   :4.083      Mean   :2.194
##  3rd Qu.:4.000      3rd Qu.:3.000
##  Max.   :5.000      Max.   :4.000
##  Phase_intervention   Campagne         Agent_collecteur   Numero_serie_cap
teur
##  Length:144         Length:144         Length:144         Length:144
##  Class :character   Class :character   Class :character   Class :character
##  Mode  :character   Mode  :character   Mode  :character   Mode  :character
##
##
##
##  Commentaire
##  Length:144
##  Class :character
##  Mode  :character
##
##
##
```

Commentaire

Statistiques descriptives de la base de données apres correction.

B.Suppression de colonnes (obligatoire)

Supprimer au minimum

Agent_collecteur

```
df$Agent_collecteur = NULL
```

Numero_serie_capteur

```
df$Numero_serie_capteur = NULL
```

Commentaire

```
df$Commentaire = NULL
```

C.Ajout de nouvelles colonnes (obligatoire)

Créer au minimum 4 nouvelles variables

C.1.Saison

```
df$Saison = ifelse((df$Date == "2025-06-01" | df$Date == "2025-07-01" | df$Da
te == "2025-08-01" | df$Date == "2025-09-01" | df$Date == "2025-10-01"), "Plu
ie", "Seche")
```

Depassement_PM25

```
df$Depassement_PM25 = ifelse(df$PM25_ugm3 > 55, "Oui", "Non")
```

PM25_log

```
df$PM25_log = log(df$PM25_ugm3)
```

Indice_confort (simple)

```
df$Indice_confort = df$Temperature_C + 0.1 * df$Humidite_pct
```

D.Visualisations (obligatoires)

Histogrammes + boxplots de PM25_ugm3

```
hist(df$PM25_ugm3, main = "Histogramme de PM2.5", xlab = "PM2.5",
     ylab = "Frequence", col = "lightblue")
```

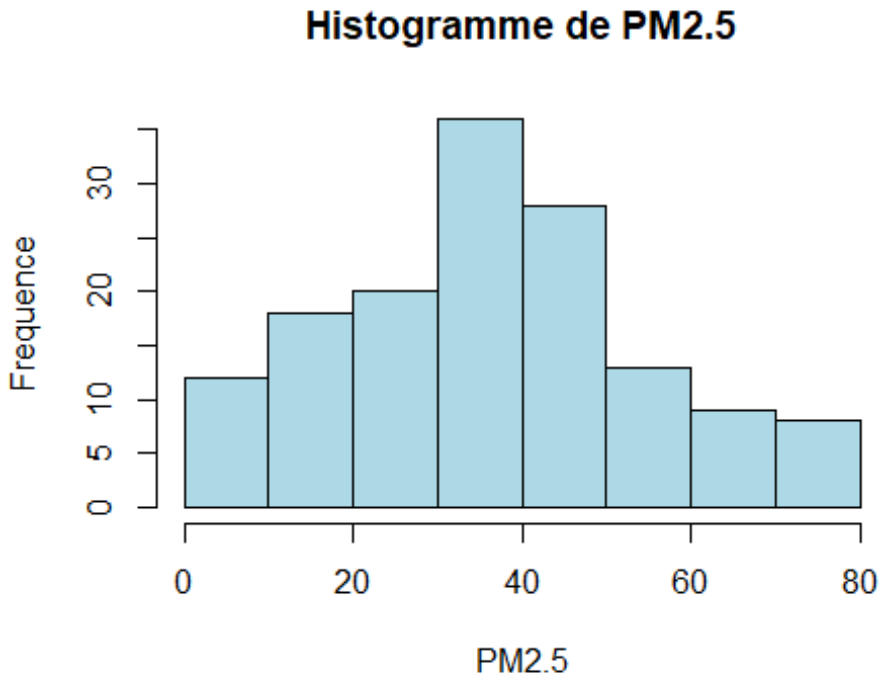

Commentaire

L'histogramme indique que la majorité des concentrations de PM2.5 se situent dans une plage modérée, avec une distribution légèrement asymétrique vers les valeurs élevées.

```
boxplot(df$PM25_ugm3,
        main = "Boxplot de PM2.5",
        ylab = "Valeur PM25_ugm3")
```

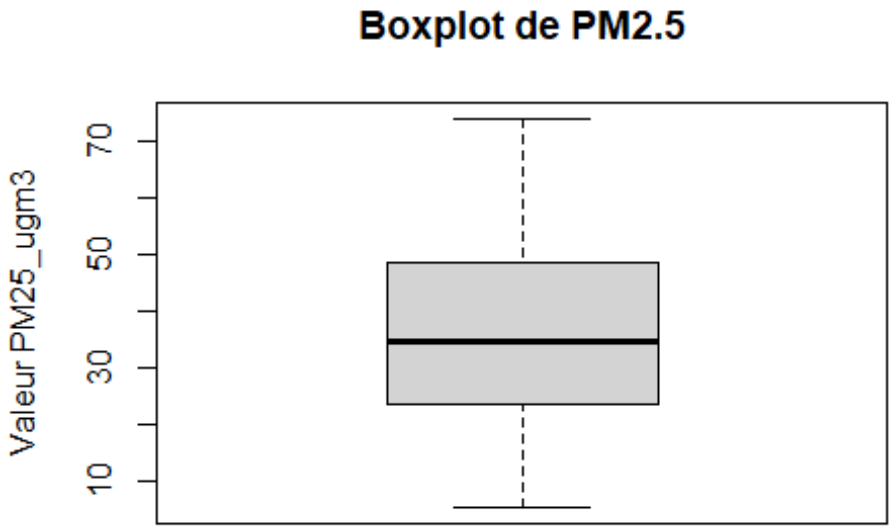

Commentaire

Ce boxplot confirme une dispersion importante des concentrations de PM2.5 et la présence de niveaux élevés pouvant représenter un risque sanitaire.

Histogrammes + boxplots de NO2_ppb

```
hist(df$NO2_ppb, main = "Histogramme de NO2_ppb", xlab = "NO2_ppb",
     ylab = "Frequence", col = "lightblue")
```

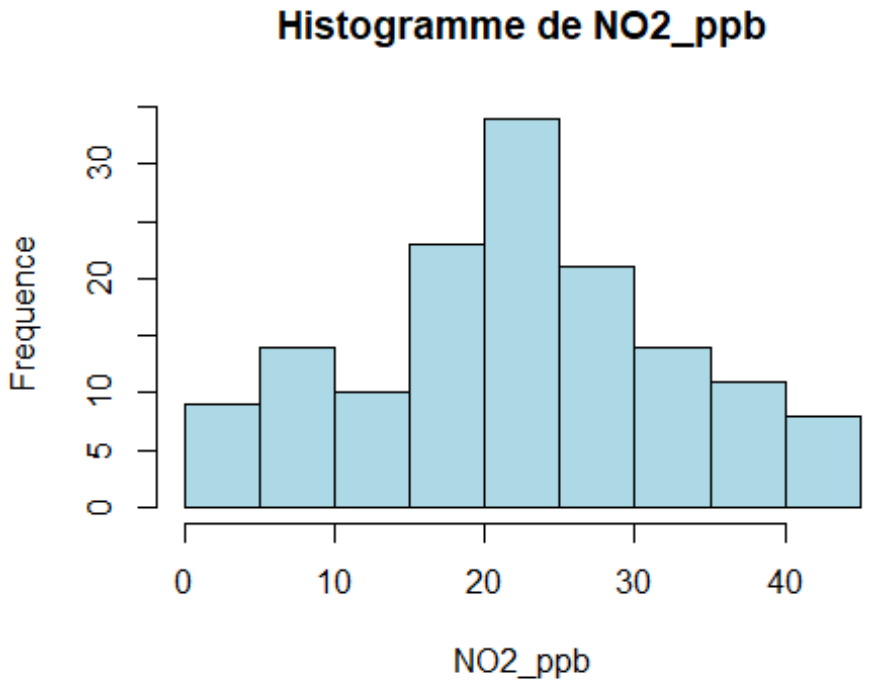

Commentaire

La distribution du NO_2 est concentrée autour de valeurs moyennes, avec une queue vers les concentrations plus élevées.

```
boxplot(df$NO2_ppb,
        main = "Boxplot de NO2_ppb",
        ylab = "Valeur NO2_ppb")
```

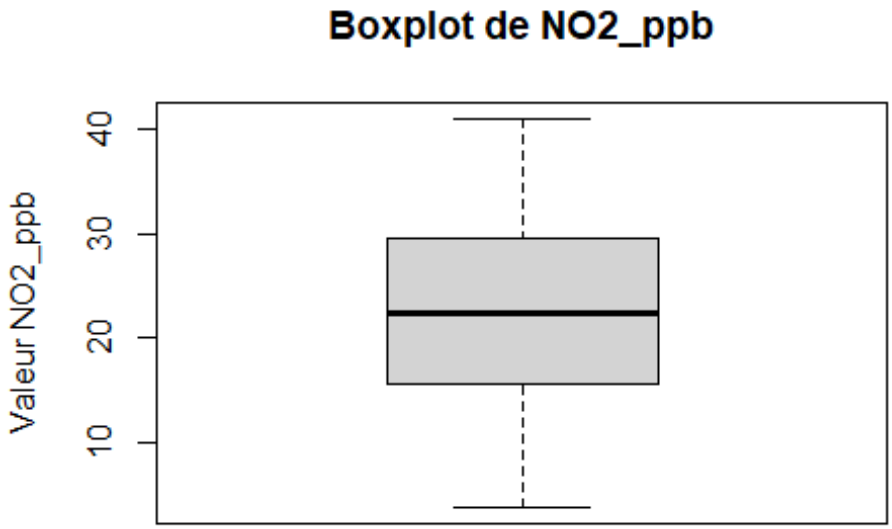

Commentaire

Le boxplot met en évidence une variabilité notable du NO_2 entre les observations, avec quelques valeurs élevées.

Histogrammes + boxplots de Bruit_dB

```
hist(df$Bruit_dB, main = "Histogramme de Bruit_dB", xlab = "Bruit_dB",
     ylab = "Frequence", col = "lightblue")
```

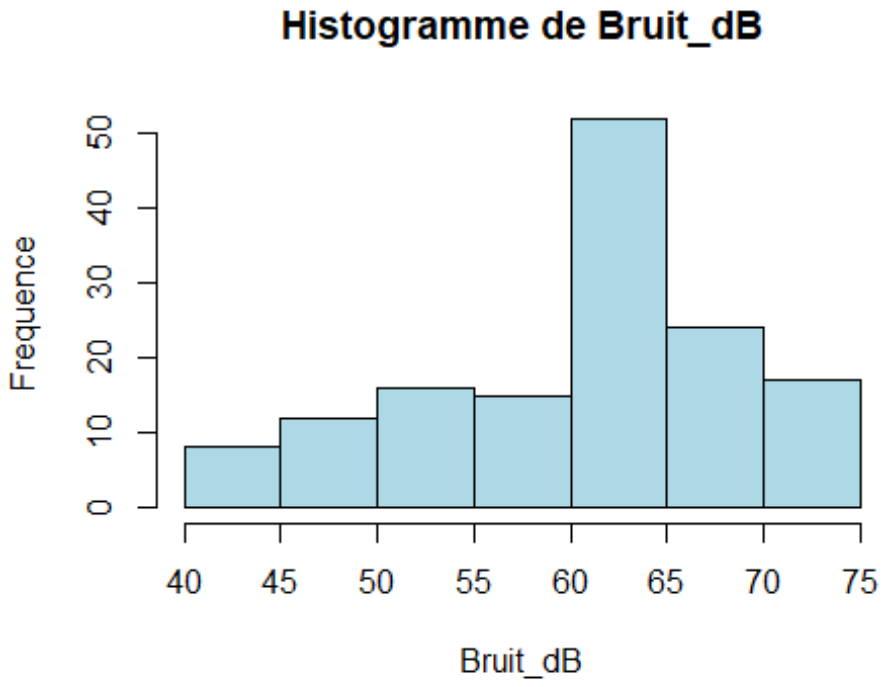

Commentaire

Ce graphique montre que les niveaux de bruit sont majoritairement compris dans une plage correspondant à des environnements urbanisés.

```
boxplot(df$Bruit_dB,
        main = "Boxplot de Bruit_dB",
        ylab = "Valeur Bruit_dB")
```

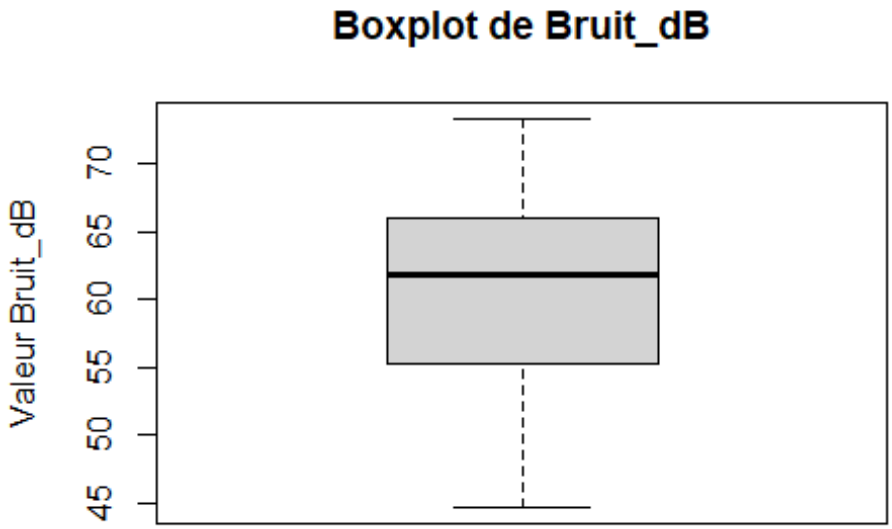

Commentaire

Le boxplot révèle une dispersion importante des niveaux sonores, avec certaines zones présentant un bruit excessif.

Boxplot de PM25_ugm3 par Type_zone

```
boxplot(PM25_ugm3 ~ Type_zone, data = df,
        main = "Pollution de l'air par type de zone",
        xlab = "Type de zone", ylab = "PM2.5",
        col = "lightblue", border = "black")
```

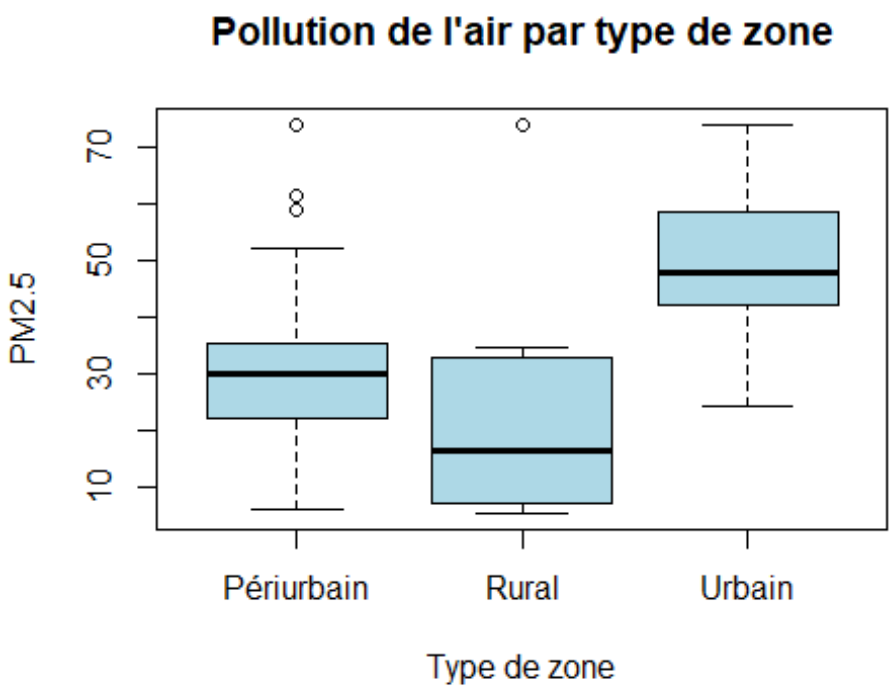

Commentaire

Les concentrations de PM2.5 sont globalement plus élevées en zone urbaine que dans les zones périurbaines et rurales.

Boxplot de PM25_ugm3 par Usage_sol

```
boxplot(PM25_ugm3 ~ Usage_sol, data = df,
        main = "Pollution de l'air par usage de sol",
        xlab = "Usage de sol", ylab = "PM2.5",
        col = "lightblue", border = "black")
```

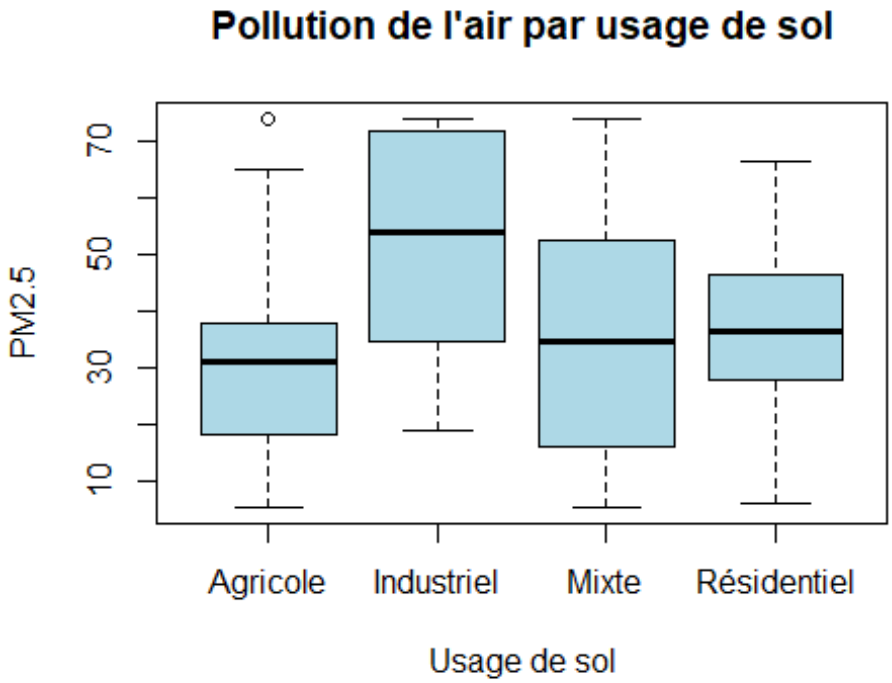

Commentaire

Les zones industrielles présentent les niveaux de PM2.5 les plus élevés, confirmant l'influence de l'activité humaine sur la pollution de l'air.

Scatter PM25_ugm3 vs NO2_ppb (avec tendance)

```
plot(df$NO2_ppb, df$PM25_ugm3,
     main = "Scatter PM2.5 vs NO2",
     xlab = "NO2",
     ylab = "PM2.5",
     abline(lm(PM25_ugm3 ~ NO2_ppb, data = df), col = "red", lwd = 2))
```

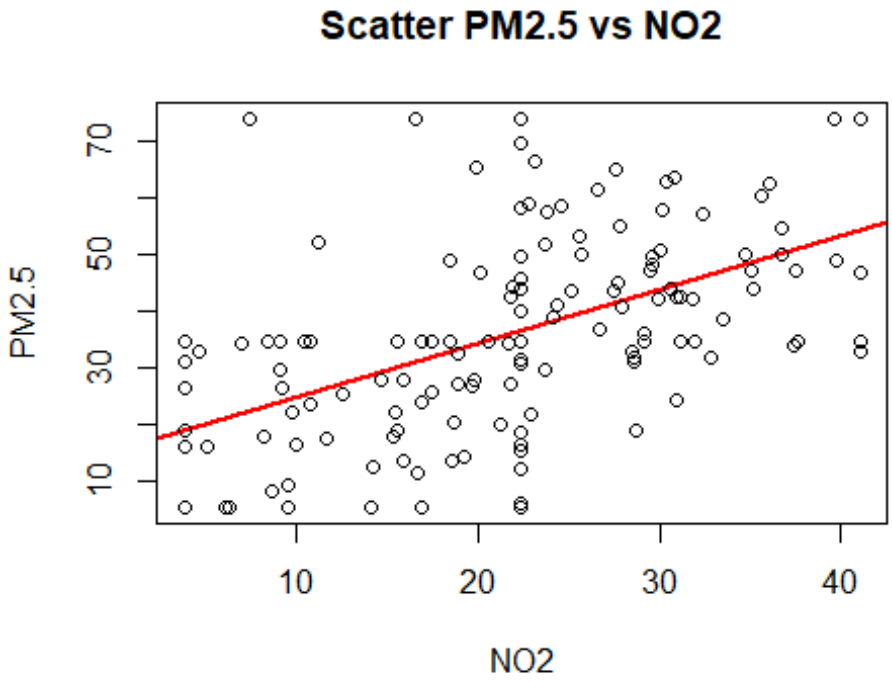

Commentaire

Le graphique met en évidence une relation positive entre PM2.5 et NO_2, suggérant des sources communes de pollution atmosphérique.

Scatter PM25_ugm3 vs NDVI

```
plot(df$NO2_ppb, df$PM25_ugm3,
     main = "Scatter PM2.5 vs NDVI",
     xlab = "NDVI",
     ylab = "PM2.5")
```

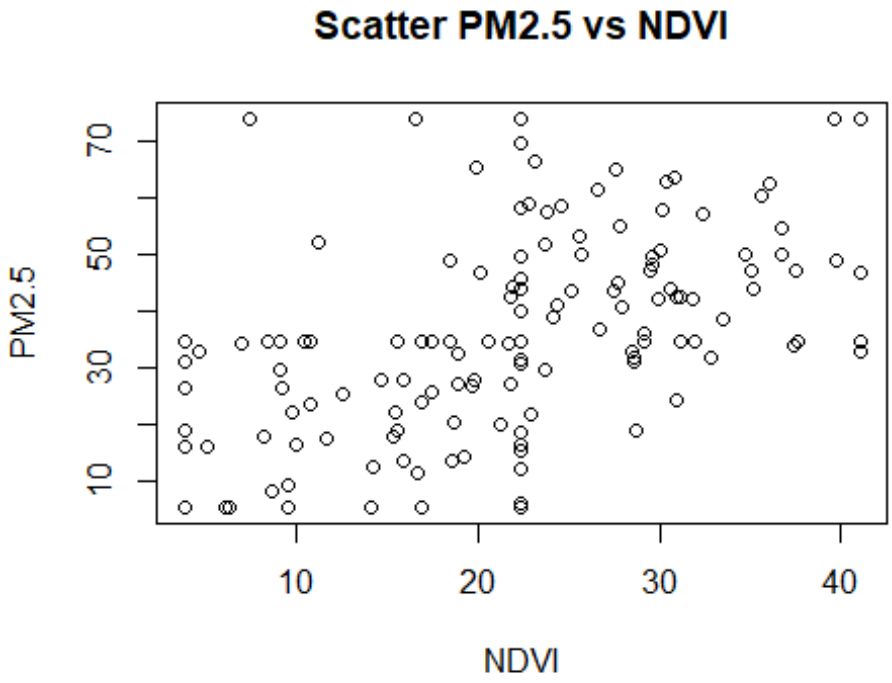

Commentaire

Ce graphique montre une relation négative : les zones à forte végétation sont associées à des concentrations plus faibles de PM2.5.

Série temporelle : PM2.5 par mois (moyenne globale ou par zone)

```
library(ggplot2)
ggplot(df, aes(x = Type_zone, y = PM25_ugm3, color = Type_zone)) +
  geom_line() +
  labs(
    title = "Évolution mensuelle de PM2.5 par zone",
    x = "Type de zone",
    y = "PM2.5 moyen "
  )
```

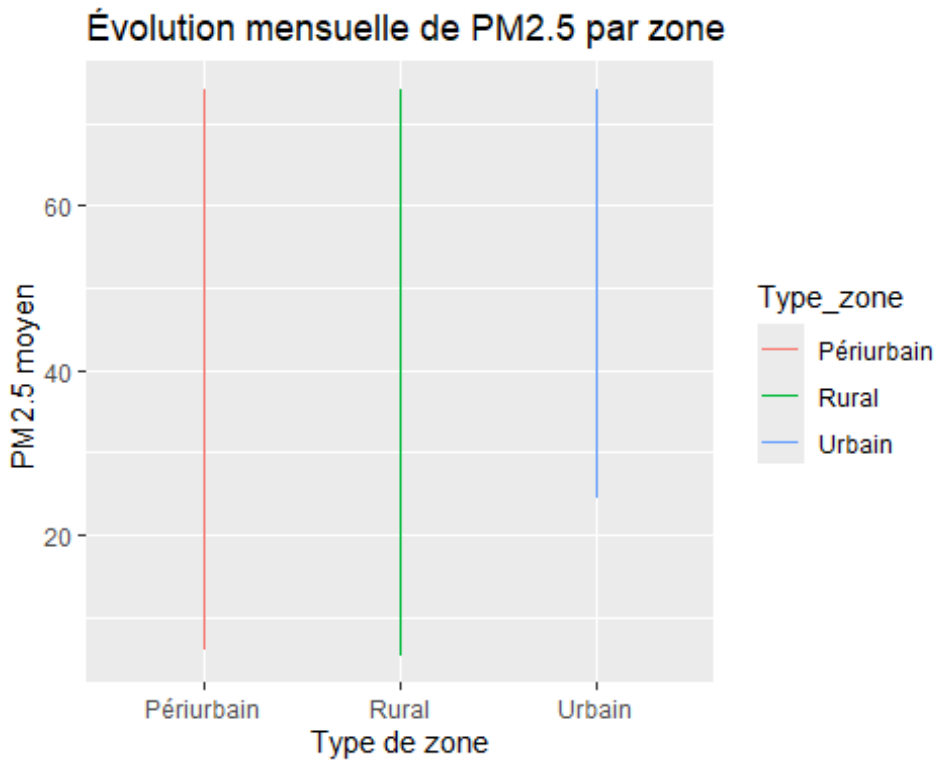

Commentaire

Les niveaux moyens de PM2.5 varient selon le type de zone, avec des valeurs plus élevées observées en milieu urbain.

Heatmap/corrélogramme (sur quanti)

Calcul de la matrice de corrélation

```
vars_quanti = df[, c("PM25_ugm3", "NO2_ppb", "Bruit_dB", "Temperature_C",
                     "Humidite_pct", "Pluie_mm", "Vent_mps", "NDVI" )]
cor_mat <- cor(vars_quanti)
library(corrplot)

## Warning: le package 'corrplot' a été compilé avec la version R 4.3.3

## corrplot 0.95 loaded

corrplot(cor_mat,
         method = "color",
         type = "upper",
         addCoef.col = "black",
         tl.col = "black")
```

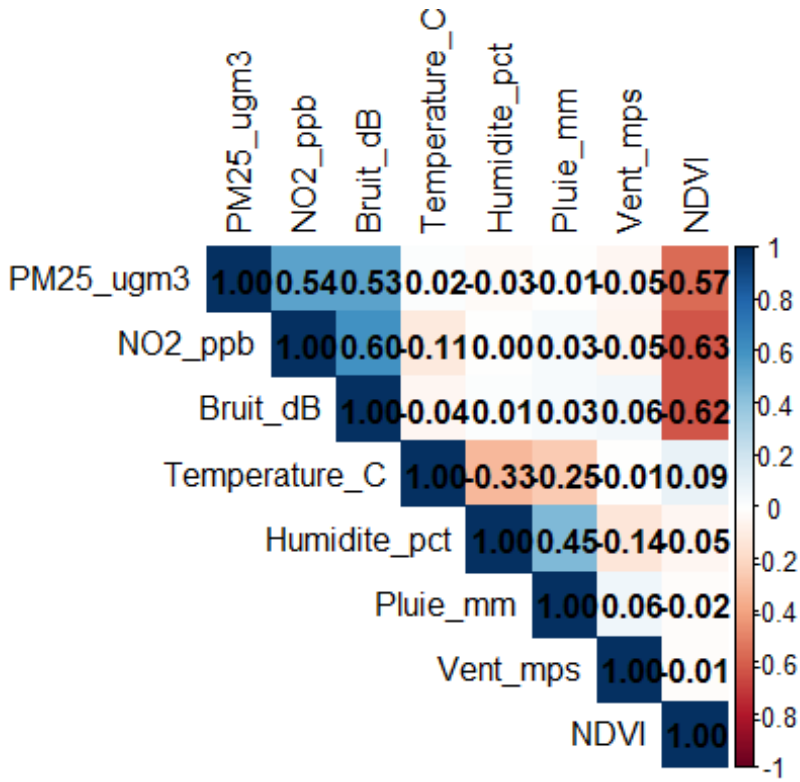

Commentaire

La matrice de corrélation met en évidence des corrélations positives entre les polluants et des corrélations négatives entre la végétation (NDVI) et la pollution.

3.Questions statistiques

3.1.Quali × Quali : Chi-deux / Fisher + V de Cramer

Le dépassement PM2.5 dépend-il du type de zone ?

Analyse univariée

Type de zone

```
table(df$Type_zone)

##
## Périurbain      Rural     Urbain
##         48         36         60
```

Depassement PM2.5

```
table(df$Depassement_PM25)

##
## Non Oui
## 121  23
```

Analyse bivariée

Tableau de contingence

```
tab <- table(df$Type_zone, df$Depassement_PM25)
tab

##
##                Non Oui
##   Périurbain    45   3
##   Rural         35   1
##   Urbain        41  19
```

Répartition du Depassement PM2.5 selon le type de zone

```
ggplot(df, aes(x = Type_zone, fill = Depassement_PM25)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition du Depassement PM2.5 selon le type de zone",
       x = "Type de zone", y = "Proportion") +
  theme_minimal()
```

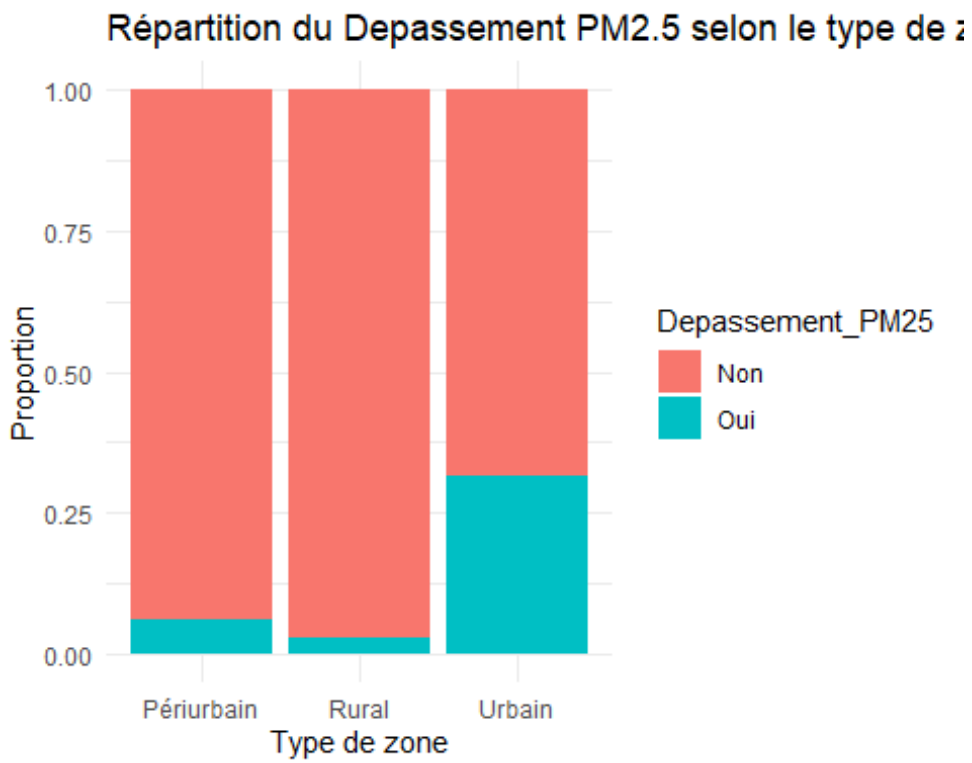

Commentaire

Les dépassements du seuil de PM2.5 sont majoritairement observés en zone urbaine.

Test du Chi-deux d'indépendance

```
chi <- chisq.test(tab)
chi
```

```
##
##  Pearson's Chi-squared test
##
## data:  tab
## X-squared = 19.062, df = 2, p-value = 7.257e-05
```

Conclusion: D'apres le test de Chi-deux, il y a un lien entre le depassement PM2.5 et le type de zone

Mesure d'intensité : V de Cramer

```r
library(vcd)

## Warning: le package 'vcd' a été compilé avec la version R 4.3.3

## Le chargement a nécessité le package : grid

assocstats(tab)

##                     X^2 df   P(> X^2)
## Likelihood Ratio 19.989  2 4.5641e-05
## Pearson          19.062  2 7.2566e-05
##
## Phi-Coefficient   : NA
## Contingency Coeff.: 0.342
## Cramer's V        : 0.364
```

Interpretation: D'apres la mesure de l'intensite de la relation avec le V de Cramer, la relation entre le depassement PM2.5 et le type de zone est forte

Conclusion: Le depassement PM2.5 dépend fortement du type de zone.

3.2.Quali × Quali : association "terrain"

Le brûlage de déchets dépend-il de la zone (urbain/périurbain/rural) ?

Analyse univariée

Type de zone

```r
table(df$Type_zone)

##
## Périurbain      Rural     Urbain
##         48         36         60
```

Le brûlage de déchets

```r
table(df$Brulage_dechets)

##
## Non Oui
## 109  35
```

Analyse bivariée

Tableau de contingence

```
tab <- table(df$Type_zone, df$Brulage_dechets)
tab

##
##                Non Oui
##   Périurbain    39   9
##   Rural         26  10
##   Urbain        44  16
```

Répartition du brûlage de déchets selon le type de zone

```
ggplot(df, aes(x = Type_zone, fill = Brulage_dechets)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition du brûlage de déchets selon le type de zone",
       x = "Type de zone", y = "Proportion") +
  theme_minimal()
```

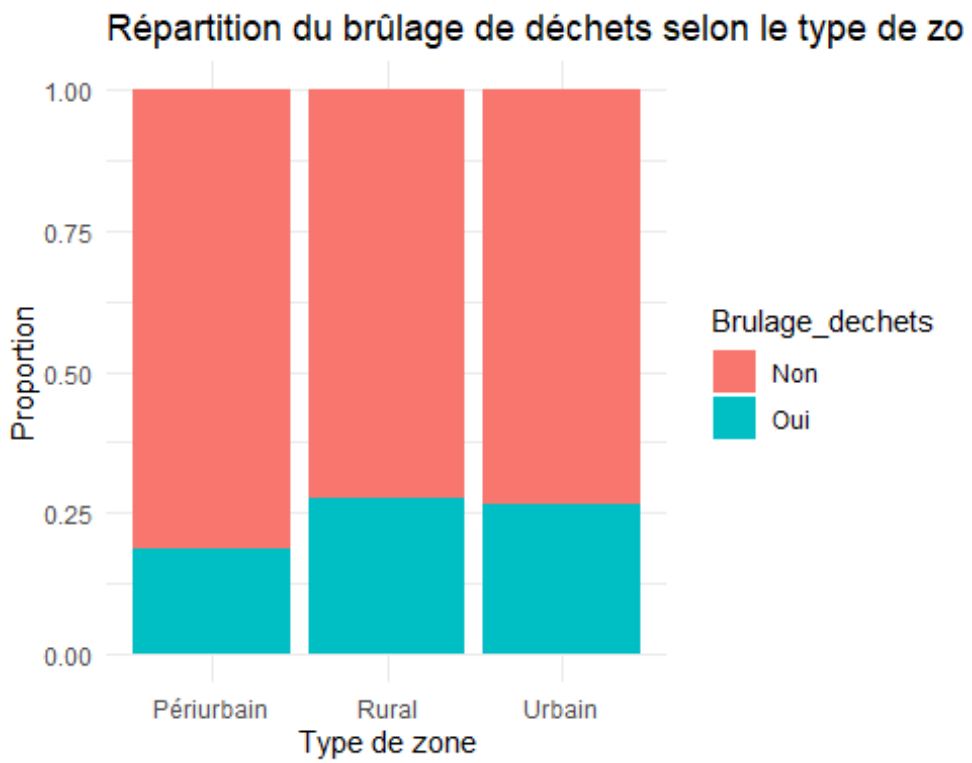

Commentaire

Le graphique montre que le brûlage de déchets est présent dans toutes les zones, avec une legere difference marquée entre elles.

Test du Chi-deux d'indépendance

```
chi <- chisq.test(tab)
chi
```

```
##
##  Pearson's Chi-squared test
##
## data:  tab
## X-squared = 1.223, df = 2, p-value = 0.5425
```

Interpretation: D'apres le test de Chi-deux, il n'y a pas de lien entre le brûlage de déchets et le type de zone

Conclusion: Le brûlage de déchets ne dépend pas du type de zone.

3.3.Quanti × Quanti : Pearson vs Spearman

PM2.5 est-il corrélé au NO_2 ?

Description univariée

Pour le PM2.5

```r
summary(df$PM25_ugm3)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   5.466  23.777  34.597  36.506  48.560  74.063
```

Commentaire

La variable étudiée présente des valeurs comprises entre 5,571 (minimum) et 73,398 (maximum).La moitié des observations se situe entre 23,777 (1er quartile) et 48,56 (3e quartile), avec une médiane de 34,597.La moyenne (36,475) est légèrement supérieure à la médiane.

```r
boxplot(df$PM25_ugm3,
        main = "Distribution de PM25_ugm3",
        ylab = "Valeur PM25_ugm3")
```

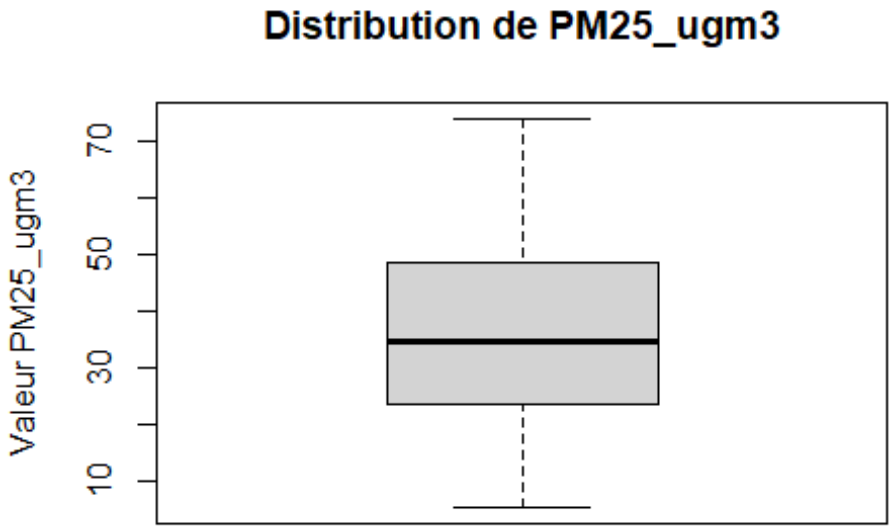

Commentaire

Ce boxplot confirme une dispersion importante des concentrations de PM2.5 et la présence de niveaux élevés pouvant représenter un risque sanitaire.

Pour le NO2

```
summary(df$NO2_ppb)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   3.835  15.595  22.393  22.272  29.604  41.037
```

Commentaire

La variable étudiée présente des valeurs comprises entre 3.952 (minimum) et 40.845 (maximum).La moitié des observations se situe entre 15.595 (1er quartile) et 29.604 (3e quartile), avec une médiane de 22.393.La moyenne (22.268) est légèrement inférieure à la médiane.

```
boxplot(df$NO2_ppb,
        main = "Distribution de NO2_ppb",
        ylab = "Valeur NO2_ppb")
```

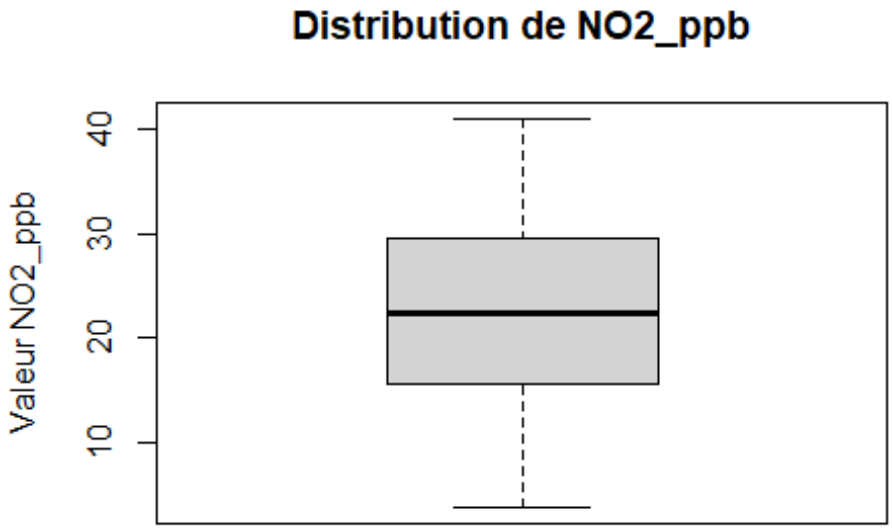

Commentaire

Le boxplot met en évidence une variabilité notable du NO_2 entre les observations, avec quelques valeurs élevées.

Description bivariée

Nuage de points entre les 2 variables

```
plot(df$PM25_ugm3, df$NO2_ppb,
     main = "Relation entre PM25_ugm3 et NO2_ppb",
     xlab = "PM25_ugm3", ylab = "NO2_ppb")
```

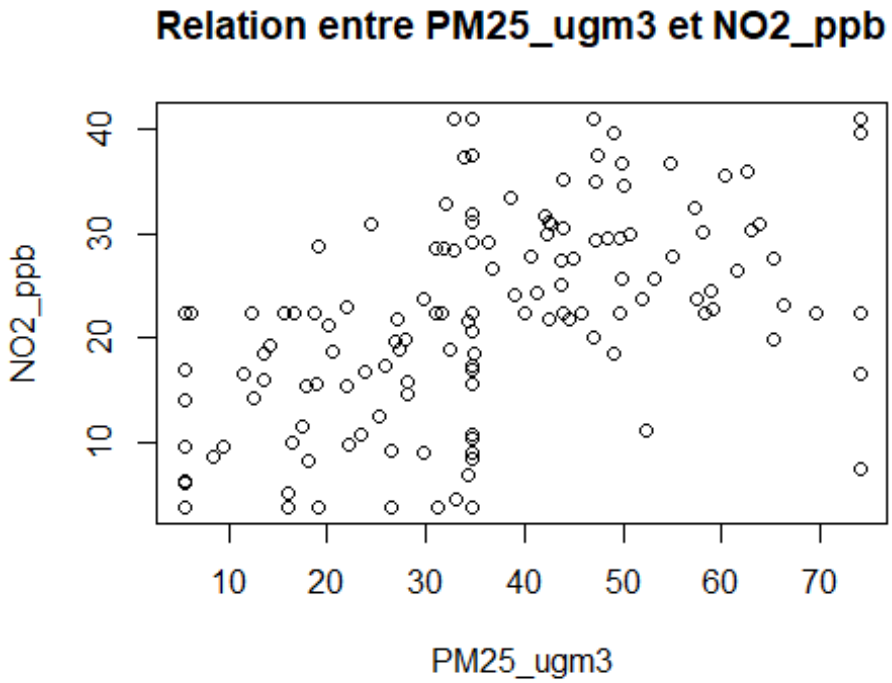

Commentaire

La relation monotone positive observée confirme la corrélation statistiquement significative entre PM2.5 et NO_2.

Vérification de la linéarité et de la normalité

Pour la linéarité (voir Description bivariée)

Il n'y a pas de linéarité entre les 2 variables

Pour la normalité

```
shapiro.test(df$PM25_ugm3)

##
##  Shapiro-Wilk normality test
##
## data:  df$PM25_ugm3
## W = 0.97101, p-value = 0.003776

shapiro.test(df$NO2_ppb)

##
##  Shapiro-Wilk normality test
##
## data:  df$NO2_ppb
## W = 0.97065, p-value = 0.003471
```

La normalité n'est pas vérifiée

Test de corrélation

```
cor.test(df$PM25_ugm3, df$NO2_ppb, method="spearman")
```

```
## Warning in cor.test.default(df$PM25_ugm3, df$NO2_ppb, method = "spearman")
:
## Impossible de calculer la p-value exacte avec des ex-aequos

##
##  Spearman's rank correlation rho
##
## data:  df$PM25_ugm3 and df$NO2_ppb
## S = 212526, p-value = 6.203e-14
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##       rho
## 0.5729331
```

Conclusion: D'apres le test de correlation de spearman, le PM2.5 est corrélé au NO2_ppb car la correlation est fortement positive monotone.

3.4.Quanti × Quanti

La végétation (NDVI) est-elle associée à la pollution (PM2.5) ?

Description univariée

Pour le PM2.5

```
summary(df$PM25_ugm3)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   5.466  23.777  34.597  36.506  48.560  74.063
```

Commentaire

La variable étudiée présente des valeurs comprises entre 5.571 (minimum) et 73.398 (maximum).La moitié des observations se situe entre 23.777 (1er quartile) et 48.560 (3e quartile), avec une médiane de 34.597.La moyenne (36.475) est légèrement supérieure à la médiane.

```
boxplot(df$PM25_ugm3,
        main = "Distribution de PM25_ugm3",
        ylab = "Valeur PM25_ugm3")
```

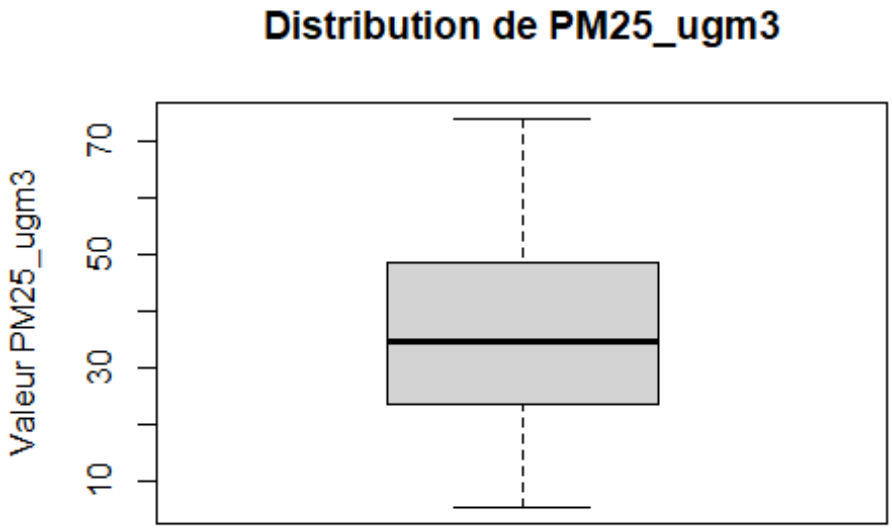

Commentaire

Ce boxplot confirme une dispersion importante des concentrations de PM2.5 et la présence de niveaux élevés pouvant représenter un risque sanitaire.

Pour la NDVI

```
summary(df$NDVI)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.07934 0.23602 0.30505 0.35257 0.46669 0.69263
```

Commentaire

La variable étudiée présente des valeurs comprises entre 0.08159 (minimum) et 0.69187 (maximum).La moitié des observations se situe entre 0.23602 (1er quartile) et 0.46669 (3e quartile), avec une médiane de 0.30505.La moyenne (0.35265) est légèrement supérieure à la médiane.

```
boxplot(df$NDVI,
        main = "Distribution de l'indice NDVI",
        ylab = "Valeur NDVI")
```

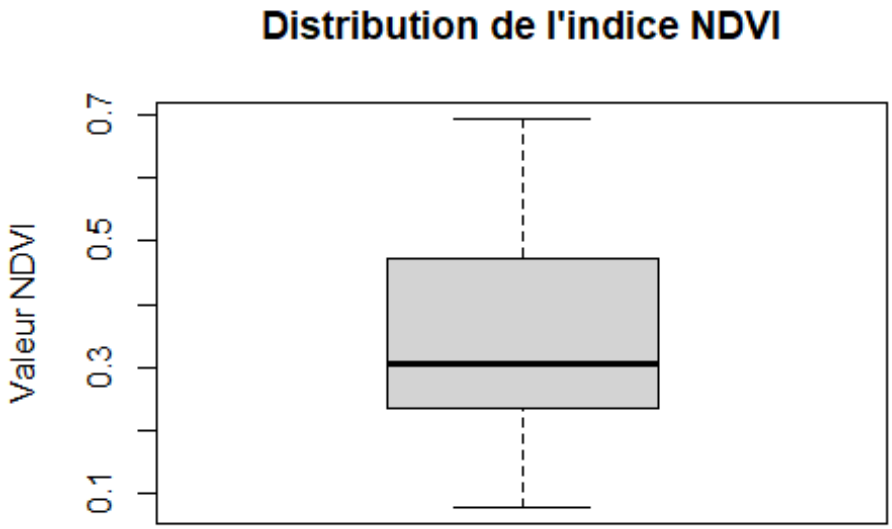

Commentaire

Ce graphique illustre la distribution statistique des valeurs de l'indice de végétation (NDVI).

Description bivariée

Nuage de points entre les 2 variables

```
plot(df$PM25_ugm3, df$NDVI,
     main = "Relation entre PM25_ugm3 et NDVI",
     xlab = "PM25_ugm3", ylab = "NDVI")
```

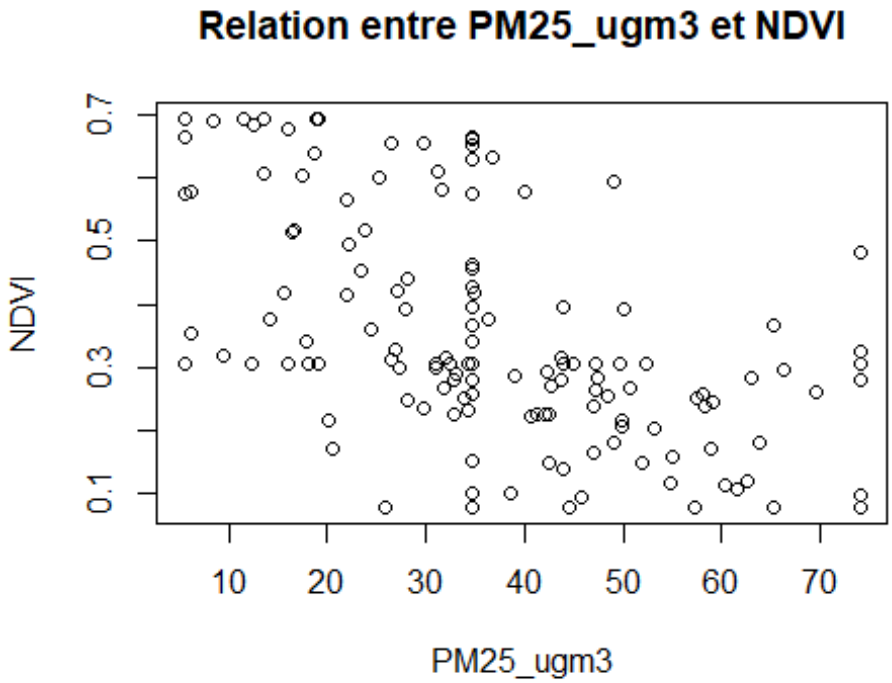

Commentaire

On observe une corrélation négative. Plus le NDVI est élevé, plus le PM2.5 a tendance à diminuer.

Vérification de la linéarité et de la normalité

Pour la linéarité (voir Description bivariée)

Il n'y a pas de linéarité entre les 2 variables

Pour la normalité

```
shapiro.test(df$PM25_ugm3)

##
##  Shapiro-Wilk normality test
##
## data:  df$PM25_ugm3
## W = 0.97101, p-value = 0.003776

shapiro.test(df$NDVI)

##
##  Shapiro-Wilk normality test
##
## data:  df$NDVI
## W = 0.92181, p-value = 4.419e-07
```

La normalité n'est pas vérifiée

Test de corrélation

```
cor.test(df$PM25_ugm3, df$NDVI, method="spearman")
```

```
## Warning in cor.test.default(df$PM25_ugm3, df$NDVI, method = "spearman"):
## Impossible de calculer la p-value exacte avec des ex-aequos

##
##  Spearman's rank correlation rho
##
## data:  df$PM25_ugm3 and df$NDVI
## S = 790638, p-value = 8.407e-15
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##        rho
## -0.5887749
```

Conclusion: D'apres le test de correlation de spearman, la NDVI est associée au PM2.5 car la correlation est fortement negative monotone.

Comparaison entre Spearman et Pearson

La corrélation de Spearman a été utilisée car les données ne respectent pas l'hypothèse de normalité, contrairement à la corrélation de Pearson qui suppose une relation linéaire et des données normalement distribuées.

3.5.Quanti × Quali (2 groupes): Student / Welch / Mann–Whitney

Le PM2.5 est-il différent quand il y a brûlage (Oui/Non) ?

```
df$Brulage_dechets <- as.factor(df$Brulage_dechets)
```

Description univariées des variables

Pour la variable qualitative 'Brulage_dechets'

```
Brulage_dechets_table <- table(df$Brulage_dechets)
Brulage_dechets_table
```

```
##
## Non Oui
## 109  35
```

Répartition par type de zone

```
barplot(Brulage_dechets_table,
        main = "Distribution de la Brulage de dechets",
        xlab = "Brulage de dechets",
        ylab = "Fréquence")
```

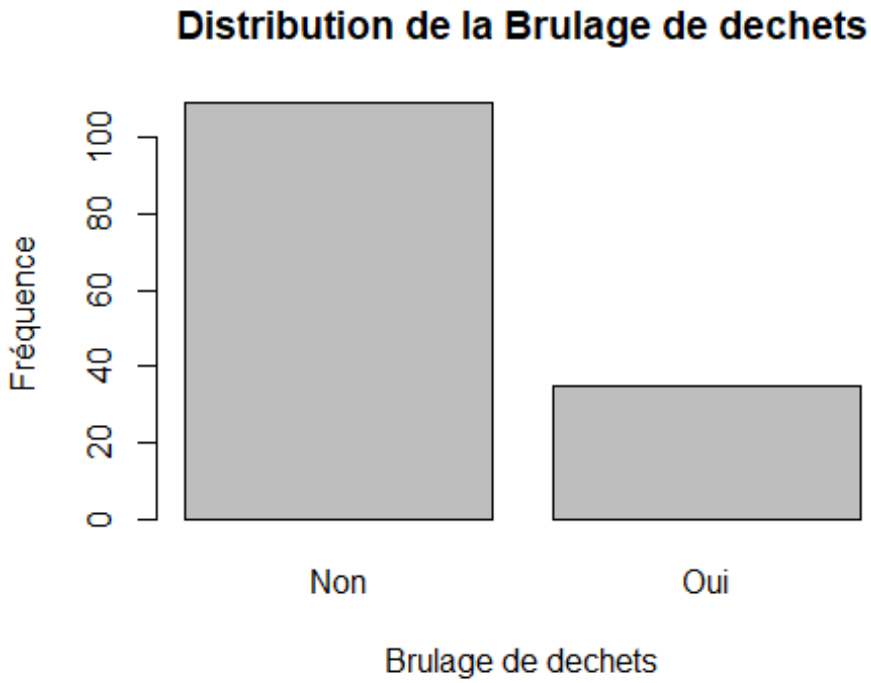

Commentaire

Une majorité de zones ne pratiquent pas le brûlage de déchets, mais une part non négligeable de l'échantillon pratique le brûlage de déchets.

Distribution de la variable quantitative 'PM25_ugm3'

```
summary(df$PM25_ugm3)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   5.466  23.777  34.597  36.506  48.560  74.063
```

Commentaire

La variable étudiée présente des valeurs comprises entre 5.571 (minimum) et 73.398 (maximum).La moitié des observations se situe entre 23.777 (1er quartile) et 48.560 (3e quartile), avec une médiane de 34.597.La moyenne (36.475) est légèrement supérieure à la médiane.

Histogramme de PM25_ugm3

```
ggplot(df, aes(x = PM25_ugm3)) +
  geom_histogram(binwidth = 0.5, fill = "skyblue", color = "black") +
  labs(title = "Distribution du PM25_ugm3",
       x = "PM25_ugm3",
       y = "Fréquence") +
  theme_minimal()
```

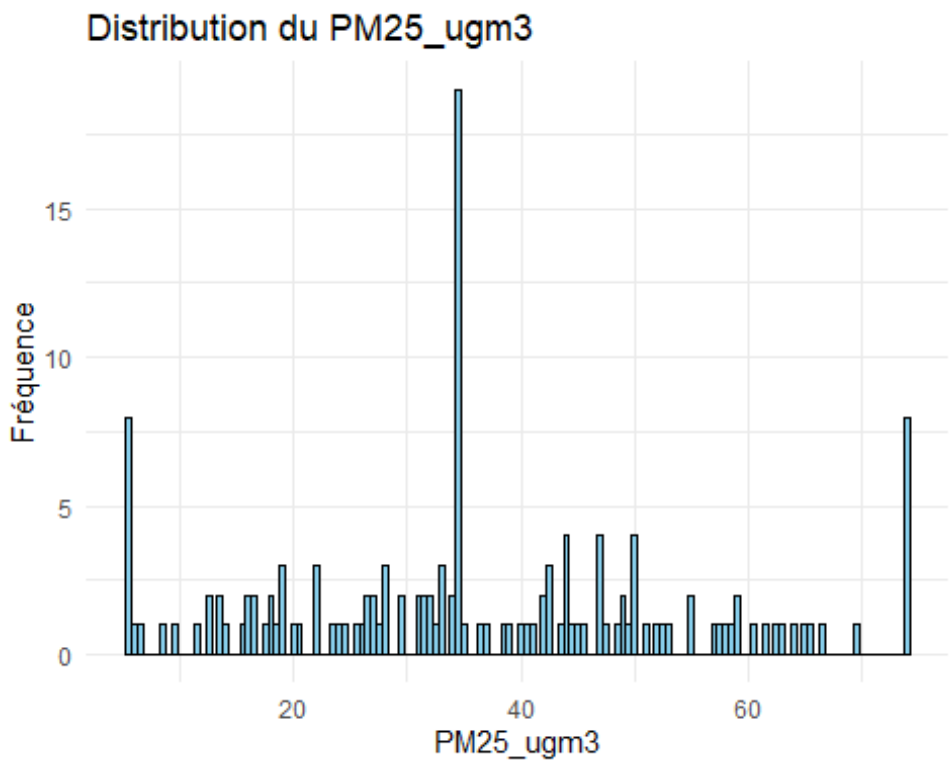

Commentaire

La pollution aux particules fines est hétérogène, avec un pic marqué autour de 35-40, indiquant une concentration fréquente à ce niveau.

Description bivariée et formulation d'une hypothése

Boxplot PM25_ugm3 par Brulage de dechets

```
ggplot(df, aes(x = Brulage_dechets, y = PM25_ugm3, fill = Brulage_dechets)) +
  geom_boxplot() +
  labs(title = "PM25_ugm3 selon la brulage de dechets",
       x = "Brulage de dechets",
       y = "PM25_ugm3") +
  theme_minimal()
```

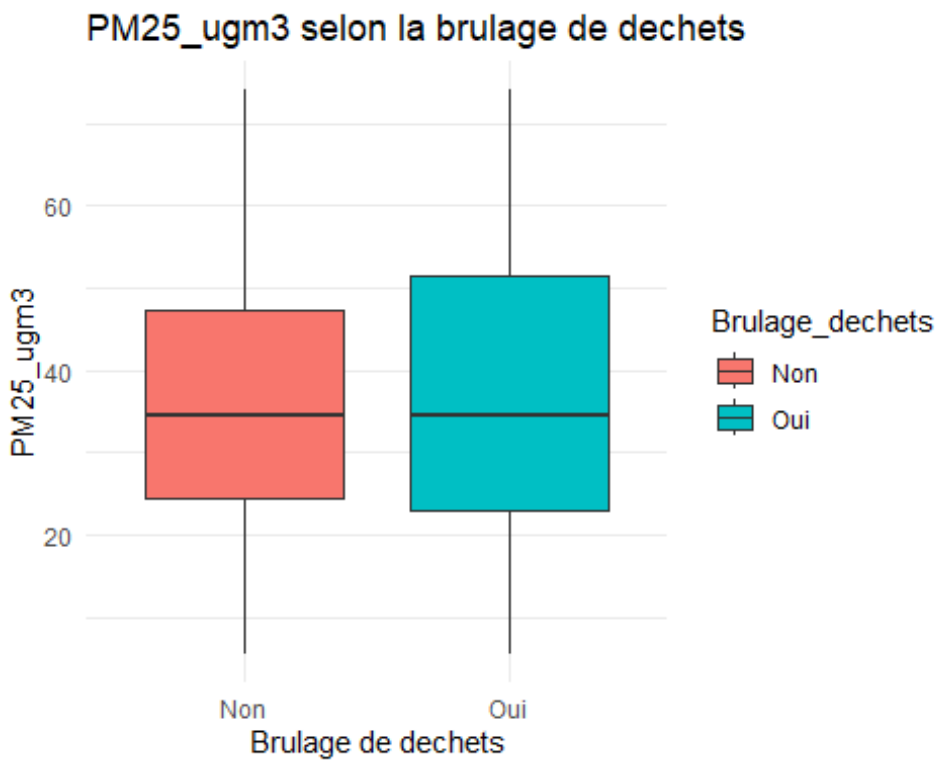

Commentaire

La médiane des PM2.5 est légèrement plus élevée là où l'on brûle des déchets, suggérant que cette pratique augmente la pollution de l'air.

Tests Statistiques

Normalité globale (ou par groupe si on veut être plus strict)

```
library(car)

## Warning: le package 'car' a été compilé avec la version R 4.3.3

## Le chargement a nécessité le package : carData

## Warning: le package 'carData' a été compilé avec la version R 4.3.3

##
## Attachement du package : 'car'

## L'objet suivant est masqué depuis 'package:DescTools':
##
##     Recode

shapiro_test_total <- shapiro.test(df$PM25_ugm3)
print(shapiro_test_total)

##
##  Shapiro-Wilk normality test
##
```

```
## data:  df$PM25_ugm3
## W = 0.97101, p-value = 0.003776
```

Interpretation: La normalité n'est pas vérifiée

Egalité des variances : Test de Levenne

```
library(car)
levene_test <- leveneTest(PM25_ugm3 ~ Brulage_dechets, data = df)
print(levene_test)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value Pr(>F)
## group   1  1.7654 0.1861
##       142
```

Interpretation: Les variances entre PM25_ugm3 et Brulage_dechets ne sont pas égales

On utilise le test de Whitney car la normalité n'est pas vérifiée

Séparation des données par brulage de dechets

```
Brulage_dechets_oui <- df$PM25_ugm3[df$Brulage_dechets == "Oui"]
Brulage_dechets_non  <- df$PM25_ugm3[df$Brulage_dechets == "Non"]
```

Test de Wilcoxon pour deux échantillons indépendants

```
wilcoxon_test <- wilcox.test(Brulage_dechets_oui, Brulage_dechets_non)
print(wilcoxon_test)
```

```
##
##  Wilcoxon rank sum test with continuity correction
##
## data:  Brulage_dechets_oui and Brulage_dechets_non
## W = 2008.5, p-value = 0.6393
## alternative hypothesis: true location shift is not equal to 0
```

Conclusion: La médiane entre PM25_ugm3 et Brulage_dechets est la même dans les deux groupes

Test de Kolmogorov-Smirnov pour comparer les distributions

```
ks_test <- ks.test(Brulage_dechets_oui, Brulage_dechets_non)
print(ks_test)
```

```
##
##  Exact two-sample Kolmogorov-Smirnov test
##
## data:  Brulage_dechets_oui and Brulage_dechets_non
## D = 0.12582, p-value = 0.7146
## alternative hypothesis: two-sided
```

Conclusion : Les distributions de PM2.5 sont statistiquement égales entre les cas avec ou sans brûlage de déchets.

3.6.Quanti × Quali (2 groupes) : bruit et industrie

Le bruit est-il plus élevé en zone industrielle (oui/non) ?

Créer Industriel_oui_non à partir de Usage_sol

```
df$Industriel_oui_non = ifelse(df$Usage_sol == "Industriel", "Oui", "Non")
```

Bruit_dB ~ Industriel_oui_non

```
df$Industriel_oui_non <- as.factor(df$Industriel_oui_non)
```

Description univariées des variables

Pour la variable qualitative 'Industriel_oui_non'

```
Industriel_oui_non_table <- table(df$Industriel_oui_non)
Industriel_oui_non_table

##
## Non Oui
## 120  24
```

Répartition par type de zone

```
barplot(Industriel_oui_non_table,
        main = "Distribution de l'Industriel_oui_non",
        xlab = "Industriel_oui_non",
        ylab = "Fréquence")
```

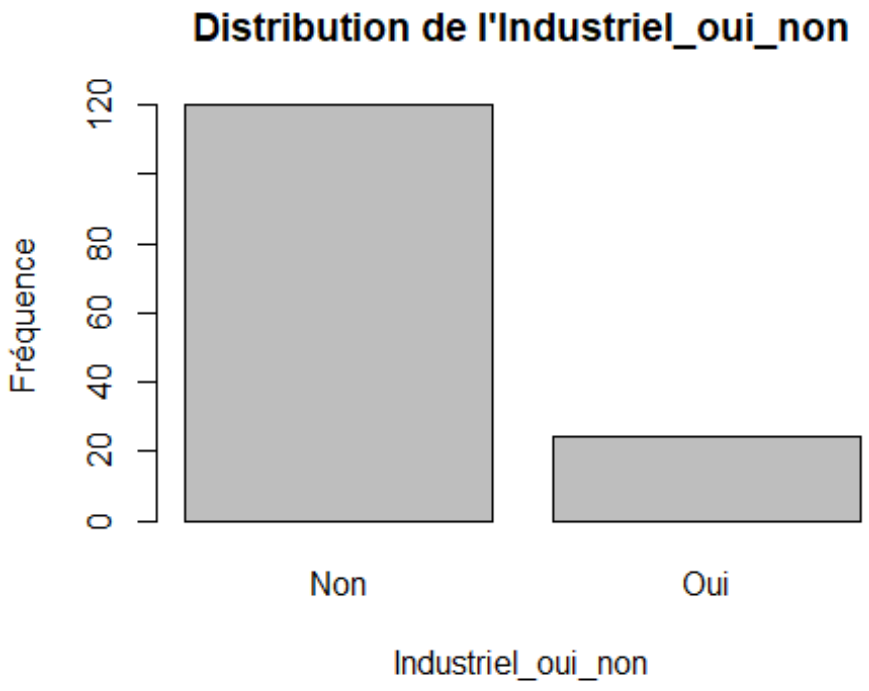

Commentaire

Le graphique montre une prédominance de zones sans activité industrielle.

Distribution de la variable quantitative 'Bruit_dB'

```
summary(df$Bruit_dB)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   44.71   55.61   61.88   60.69   66.03   73.31
```

Commentaire

La variable étudiée présente des valeurs comprises entre 44.78 (minimum) et 73.31 (maximum).La moitié des observations se situe entre 55.61 (1er quartile) et 66.03 (3e quartile), avec une médiane de 61.88.La moyenne (60.69) est légèrement supérieure à la médiane.

Histogramme de Bruit_dB

```
ggplot(df, aes(x = Bruit_dB)) +
  geom_histogram(binwidth = 0.5, fill = "skyblue", color = "black") +
  labs(title = "Distribution du Bruit_dB",
       x = "Bruit_dB",
       y = "Fréquence") +
  theme_minimal()
```

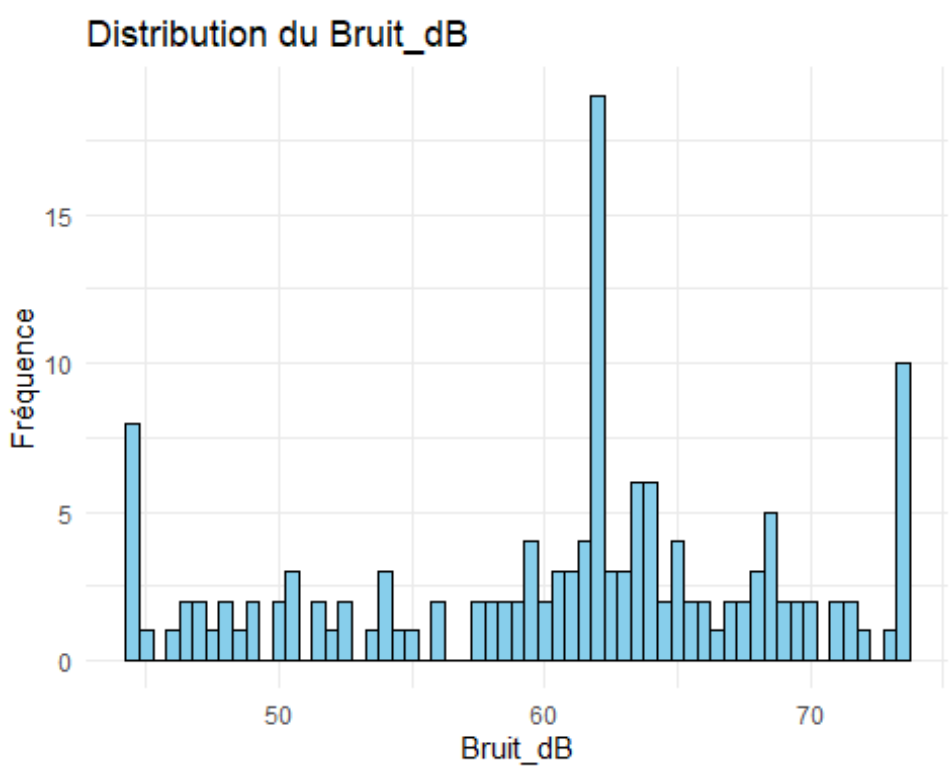

Commentaire

Le graphique montre une forte concentration de niveaux sonores autour de 65 dB, avec quelques zones très bruyantes (> 75 dB).

Description bivariée et formulation d'une hypothèse

Boxplot Bruit_dB par Industriel_oui_non

```
ggplot(df, aes(x = Industriel_oui_non, y = Bruit_dB, fill = Industriel_oui_no
n)) +
  geom_boxplot() +
  labs(title = "Bruit_dB selon l'Industriel_oui_non",
       x = "Industriel_oui_non",
       y = "Bruit_dB") +
  theme_minimal()
```

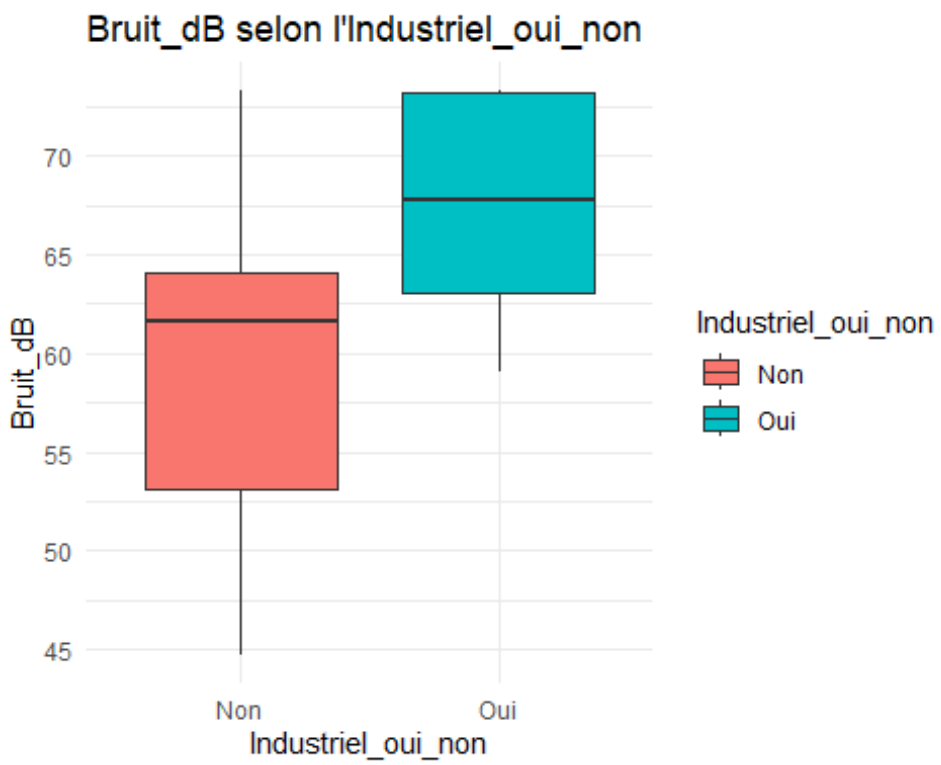

Commentaire

Les zones pratiquant le brûlage de déchets sont également beaucoup plus bruyantes (médiane plus haute), ce qui peut indiquer des zones d'activités mixtes ou informelles.

Tests Statistiques

Normalité globale (ou par groupe si on veut être plus strict)

```
library(car)
shapiro_test_total <- shapiro.test(df$Bruit_dB)
print(shapiro_test_total)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df$Bruit_dB
## W = 0.94055, p-value = 8.687e-06
```

Interpretation : La normalité n'est pas vérifiée

Egalité des variances : Test de Levenne

```r
library(car)
levene_test <- leveneTest(Bruit_dB ~ Industriel_oui_non, data = df)
print(levene_test)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value Pr(>F)
## group   1  2.2876 0.1326
##       142
```

Interpretation: Les variances entre Bruit_dB et Industriel_oui_non sont égales

On utilise le test de Whitney car la normalité n'est pas vérifiée

Séparation des données par brulage de dechets

```r
Industriel_oui <- df$Bruit_dB[df$Industriel_oui_non == "Oui"]
Industriel_non  <- df$Bruit_dB[df$Industriel_oui_non == "Non"]
```

Test de Wilcoxon pour deux échantillons indépendants

```r
wilcoxon_test <- wilcox.test(Industriel_oui, Industriel_non)
print(wilcoxon_test)
```

```
##
##  Wilcoxon rank sum test with continuity correction
##
## data:  Industriel_oui and Industriel_non
## W = 2323, p-value = 2.179e-06
## alternative hypothesis: true location shift is not equal to 0
```

Conclusion: La médiane entre Bruit_dB et Industriel_oui_non est différente dans les deux groupes

Test de Kolmogorov-Smirnov pour comparer les distributions

```r
ks_test <- ks.test(Industriel_oui, Industriel_non)
print(ks_test)
```

```
##
##  Exact two-sample Kolmogorov-Smirnov test
##
## data:  Industriel_oui and Industriel_non
## D = 0.45833, p-value = 0.0002152
## alternative hypothesis: two-sided
```

Conclusion : Le niveau de bruit diffère significativement selon le caractère industriel de la zone.

3.7.Quanti × Quali (>2 groupes) : ANOVA / Welch ANOVA / Kruskal–Wallis

Le bruit diffère-t-il selon le type de zone ?

Description univariée

Type_zone

```
table_Type_zone <- table(df$Type_zone)
print(table_Type_zone)

##
## Périurbain      Rural     Urbain
##         48         36         60

barplot(table_Type_zone,
        main = "Répartition du type de zone",
        xlab = "Type de zone",
        ylab = "Fréquence")
```

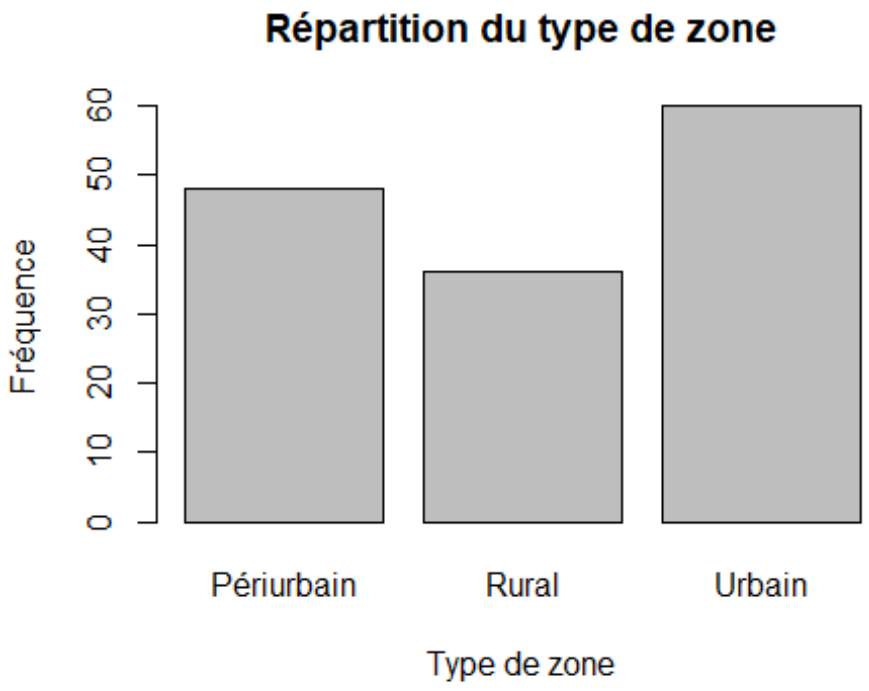

Commentaire

L'échantillon est équilibré, avec une légère prédominance des zones urbaines, suivies du périurbain et du rural.

Bruit_dB

```
summary(df$Bruit_dB)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   44.71   55.61   61.88   60.69   66.03   73.31
```

Commentaire

La variable étudiée présente des valeurs comprises entre 44.78 (minimum) et 73.31 (maximum).La moitié des observations se situe entre 55.61 (1er quartile) et 66.03 (3e quartile), avec une médiane de 61.88.La moyenne (60.69) est légèrement supérieure à la médiane.

```
hist(df$Bruit_dB,
     main = "Distribution du Bruit_dB",
     xlab = "Bruit_dB",
     col = "skyblue",
     border = "black")
```

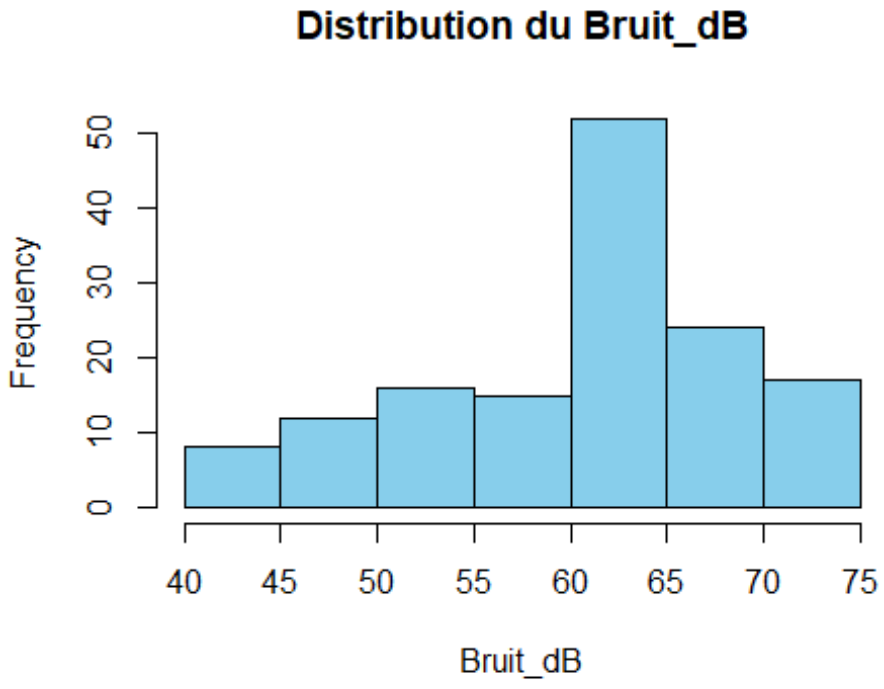

Commentaire

Ce graphique montre que les niveaux de bruit sont majoritairement compris dans une plage correspondant à des environnements urbanisés.

Description bivariée

Boxplot Bruit_dB x Type de zone

```
ggplot(df, aes(x = Type_zone, y = Bruit_dB, fill = Type_zone)) +
  geom_boxplot() +
  labs(title = "Bruit_dB selon le Type de zone",
       x = "Type de zone",
       y = "Bruit_dB") +
  theme_minimal()
```

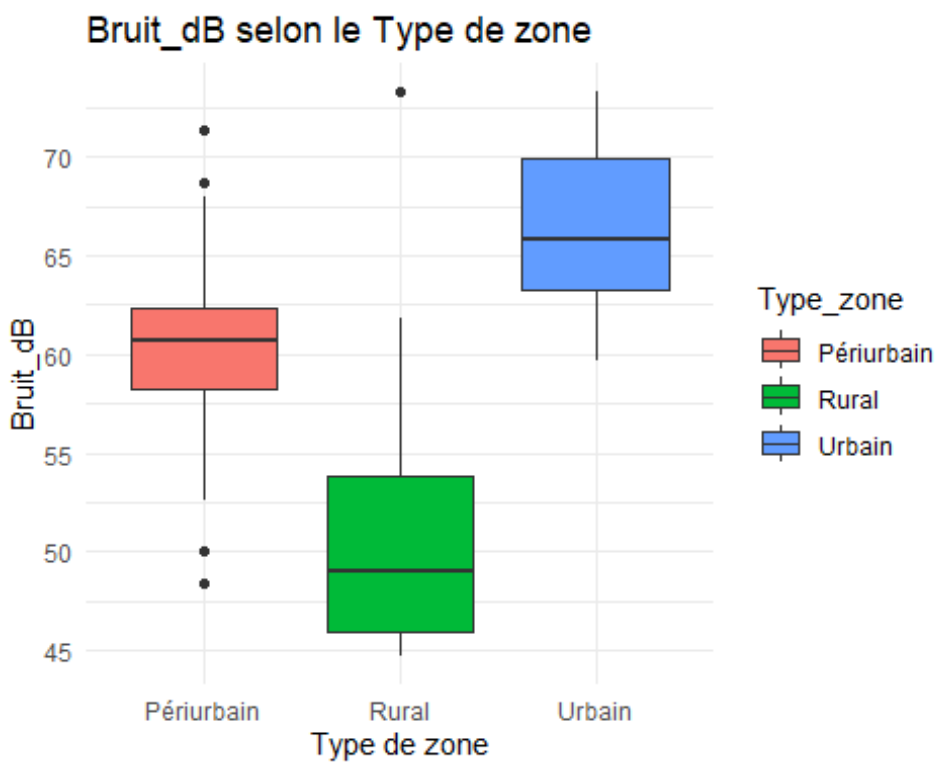

Commentaire

La zone urbaine est la plus bruyante, tandis que la zone rurale est la plus calme. Le périurbain se situe entre les deux.

Tests statistiques

vérification de la normalité

```
shapiro.test(df$Bruit_dB)

##
##  Shapiro-Wilk normality test
##
## data:  df$Bruit_dB
## W = 0.94055, p-value = 8.687e-06
```

Conclusion: La normalité n'est pas vérifiée

vérification de l'égalité des variances (levenne)

```
library(car)
leveneTest(Bruit_dB ~ Type_zone, data = df)

## Warning in leveneTest.default(y = y, group = group, ...): group coerced to
## factor.

## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value  Pr(>F)
## group   2  2.7422 0.06787 .
##       141
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Conclusion: L'égalité des variances est vérifiée

Test de Kruskal-Wallis

```
kruskal_test <- kruskal.test(Bruit_dB ~ Type_zone, data = df)
print(kruskal_test)

##
##  Kruskal-Wallis rank sum test
##
## data:  Bruit_dB by Type_zone
## Kruskal-Wallis chi-squared = 79.665, df = 2, p-value < 2.2e-16
```

Conclusion: Au moins un groupe a une distribution différente, donc le bruit diffère selon le type de zone

3.8.Quanti × Quali (>2 groupes)

Le PM2.5 diffère-t-il selon l'usage du sol ?

Description univariée

Usage_sol

```
table_Usage_sol <- table(df$Usage_sol)
print(table_Usage_sol)

##
##    Agricole  Industriel       Mixte Résidentiel
##          60          24          24          36

barplot(table_Usage_sol,
        main = "Répartition de l'usage du sol",
        xlab = "Usage_sol",
        ylab = "Fréquence")
```

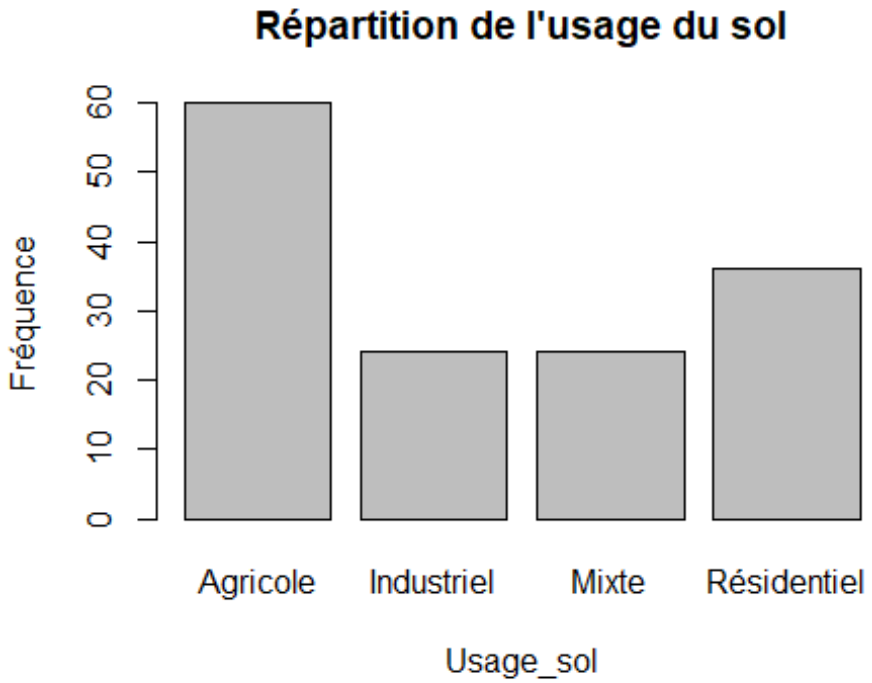

Commentaire

L'usage agricole est le plus représenté dans les données, suivi par le résidentiel, l'industriel et le mixte.

PM25_ugm3

```
summary(df$PM25_ugm3)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   5.466  23.777  34.597  36.506  48.560  74.063
```

Commentaire

La variable étudiée présente des valeurs comprises entre 5.571 (minimum) et 73.398 (maximum).La moitié des observations se situe entre 23.777 (1er quartile) et 48.560 (3e quartile), avec une médiane de 34.597.La moyenne (36.475) est légèrement supérieure à la médiane.

```
hist(df$PM25_ugm3,
     main = "Distribution de la PM25_ugm3",
     xlab = "PM25_ugm3",
     col = "skyblue",
     border = "black")
```

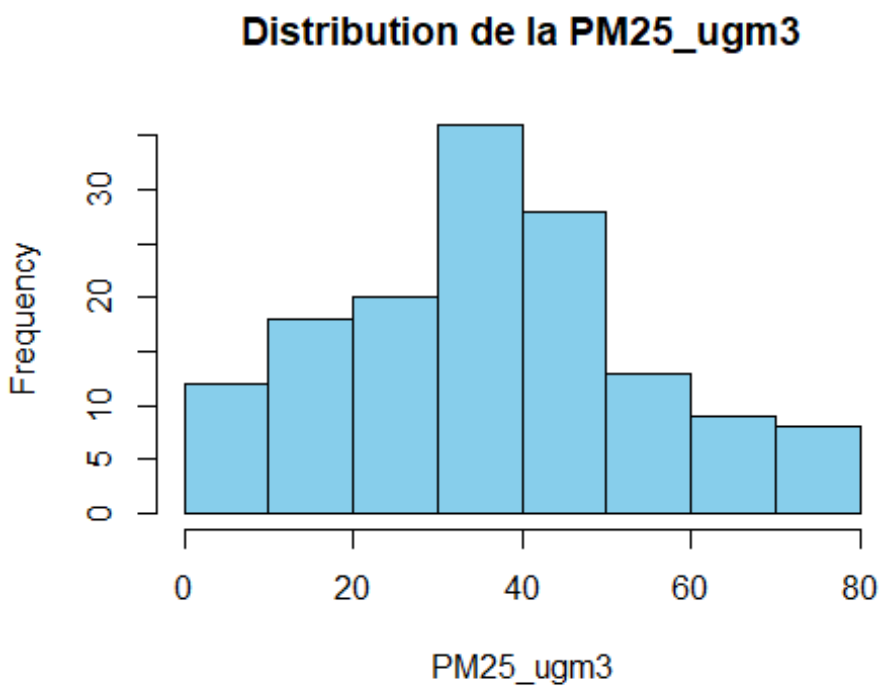

Commentaire

L'histogramme indique que la majorité des concentrations de PM2.5 se situent dans une plage modérée, avec une distribution légèrement asymétrique vers les valeurs élevées.

Description bivariée

Boxplot Température x Usage du sol

```
ggplot(df, aes(x = Usage_sol, y = PM25_ugm3, fill = Usage_sol)) +
  geom_boxplot() +
  labs(title = "PM25_ugm3 selon l'usage du sol",
       x = "Usage_sol",
       y = "PM25_ugm3") +
  theme_minimal()
```

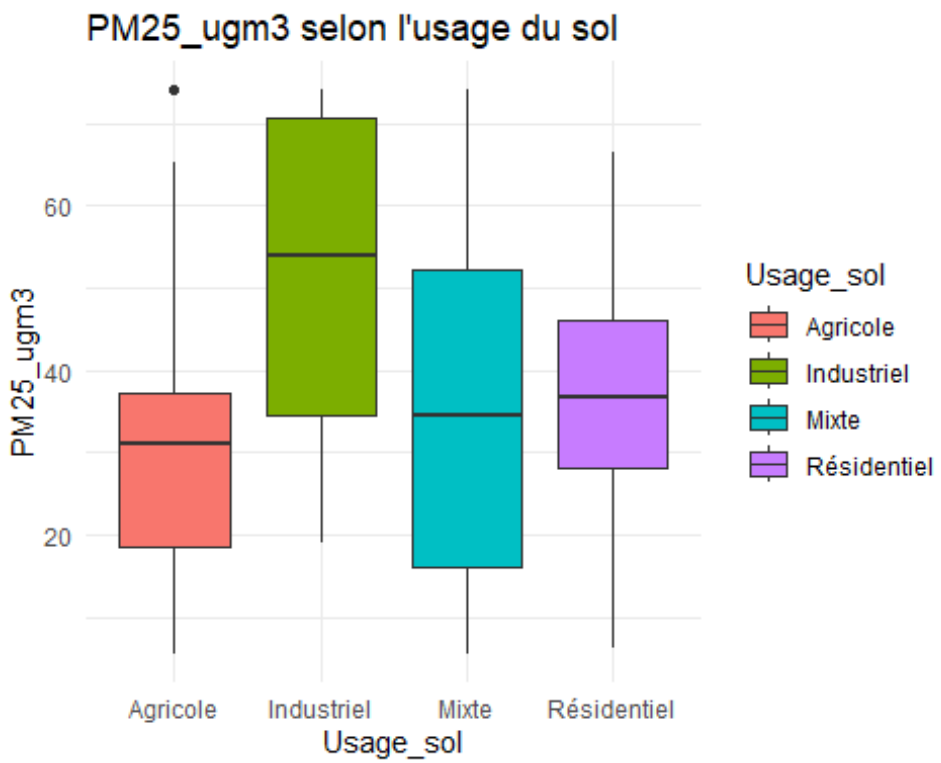

Commentaire

C'est dans les zones industrielles que la pollution aux particules fines est la plus élevée et la plus variable. Les zones résidentielles et agricoles présentent des niveaux plus bas.

Tests statistiques

vérification de la normalité

```
shapiro.test(df$PM25_ugm3)

##
##  Shapiro-Wilk normality test
##
## data:  df$PM25_ugm3
## W = 0.97101, p-value = 0.003776
```

Conclusion: La normalité n'est pas vérifiée

vérification de l'égalité des variances (levenne)

```
library(car)
leveneTest(PM25_ugm3 ~ Usage_sol, data = df)

## Warning in leveneTest.default(y = y, group = group, ...): group coerced to
## factor.

## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value  Pr(>F)
## group   3  2.8755 0.03842 *
```

```
##       140
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Conclusion: L'égalité des variances n'est pas vérifiée

Test de Kruskal-Wallis

```
kruskal_test <- kruskal.test(PM25_ugm3 ~ Usage_sol, data = df)
print(kruskal_test)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  PM25_ugm3 by Usage_sol
## Kruskal-Wallis chi-squared = 24.087, df = 3, p-value = 2.396e-05
```

Conclusion: Au moins une moyenne est différente, donc le PM2.5 diffère selon l'usage du sol

3.9.Ordinale × Ordinale : Tau de Kendall (ou Spearman)

La perception de la qualité de l'air est-elle liée à la gêne du bruit ?

```
Air <- df$Perception_air_1a5
Bruit <- df$Gene_bruit_1a5
```

Test de correlation

```
cor.test(Air, Bruit, method="spearman")
```

```
## Warning in cor.test.default(Air, Bruit, method = "spearman"): Impossible d
e
## calculer la p-value exacte avec des ex-aequos
```

```
##
##  Spearman's rank correlation rho
##
## data:  Air and Bruit
## S = 645239, p-value = 0.0003065
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##        rho
## -0.2965979
```

```
cor_kendall  <- cor(Air, Bruit, method = "kendall")
print(cor_kendall)
```

```
## [1] -0.2708027
```

Conclusion: Oui, la perception de la qualité de l'air est fortement liée à la gêne du bruit, avec une correlation négative parfaite.

3.10.Données appariées : t apparié / Wilcoxon signé

```
library(dplyr)

## Warning: le package 'dplyr' a été compilé avec la version R 4.3.3

##
## Attachement du package : 'dplyr'

## L'objet suivant est masqué depuis 'package:car':
##
##     recode

## Les objets suivants sont masqués depuis 'package:stats':
##
##     filter, lag

## Les objets suivants sont masqués depuis 'package:base':
##
##     intersect, setdiff, setequal, union

df_poussiere <- df %>%
  filter(Campagne == "Campagne_poussiere")

df_apparie <- df_poussiere %>%
  filter(Phase_intervention %in% c("Avant", "Après")) %>%
  select(Station, Phase_intervention, PM25_ugm3) %>%
  tidyr::pivot_wider(names_from = Phase_intervention,
                     values_from = PM25_ugm3)
df_apparie

## # A tibble: 12 × 3
##    Station Avant Après
##    <chr>   <dbl> <dbl>
##  1 ST01     60.4 69.6
##  2 ST02     42.4 34.0
##  3 ST03     55.0 42.7
##  4 ST04     63.8 31.9
##  5 ST05     47.1 24.4
##  6 ST06     42.1 59.1
##  7 ST07     17.9  9.50
##  8 ST08     32.5 34.6
##  9 ST09     17.4  5.47
## 10 ST10     34.6 31.3
## 11 ST11     26.5 14.2
## 12 ST12     31.0  5.47
```

Calculer les différences (Après – Avant)

```
df_apparie <- df_apparie %>%
  mutate(diff = Après - Avant)
df_apparie
```

```
## # A tibble: 12 × 4
##    Station Avant Après   diff
##    <chr>   <dbl> <dbl>  <dbl>
##  1 ST01     60.4 69.6    9.27
##  2 ST02     42.4 34.0   -8.47
##  3 ST03     55.0 42.7  -12.2
##  4 ST04     63.8 31.9  -31.9
##  5 ST05     47.1 24.4  -22.7
##  6 ST06     42.1 59.1   17.0
##  7 ST07     17.9  9.50  -8.44
##  8 ST08     32.5 34.6    2.11
##  9 ST09     17.4  5.47 -12.0
## 10 ST10     34.6 31.3   -3.34
## 11 ST11     26.5 14.2  -12.3
## 12 ST12     31.0  5.47 -25.5
```

Tester la normalité des différences (par station)

```r
shapiro.test(df_apparie$diff)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df_apparie$diff
## W = 0.97152, p-value = 0.9261
```

La normalite est verifiee

Test t apparié

```r
t.test(df_apparie$Après, df_apparie$Avant, paired = TRUE)
```

```
##
##  Paired t-test
##
## data:  df_apparie$Après and df_apparie$Avant
## t = -2.2221, df = 11, p-value = 0.04819
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
##  -17.98141977  -0.08580579
## sample estimates:
## mean difference
##       -9.033613
```

Conclusion: On constate que: ($p < 0.05$) et diff < 0, Donc la campagne a réduit significativement les concentrations de PM2.5.